Kunstig intelligens og filosofi
Introduksjon

Kunstig intelligens og filosofi (FIL1010), INN

Hedda Hassel Mørch

23.01.2026

I dag

- Introduksjon
  - Hva er kunstig intelligens?
    - Hvordan fungerer det? (helt grunnleggende)
  - Hva er filosofi?
  - Hva slags filosofiske spørsmål oppstår om KI?
- Praktisk informasjon
- Første tema: <u>bevissthet</u>

Kunstig intelligens

- Kunstig intelligens – forkortes KI (eller AI på engelsk)
  - «The automation of activities that we associate with human thinking, activities such as decision-making, problem solving, learning ... » (Bellman, 1978 sitert i Russell og Norvig)
  - En av flere mulige definisjoner
- Har utviklet seg kraftig – og utover de flestes forventinger
- Typisk oppfatning – i hvert fall frem til nylig:
  - Det finnes ting som mennesker kan, men maskiner aldri vil klare.
  - → «Maskiner vil aldri klare X»

«Maskiner vil aldri klare X»

- Maskiner kan aldri <u>regne</u> eller <u>gjøre logikk</u>
  - Motbevist av de første datamaskinene (fra og med 1600-tallet, elektroniske fra 1940-tallet)
- Maskiner kan aldri slå stormestere i sjakk
  - Motbevist av Deep Blue (slo Kasparov i sjakk, 1997)
  - Basert på rå regnekraft (klassisk KI)
- Maskiner kan aldri slå stormestere i Go
  - For komplekst til å vinnes ved rå regnekraft – trenger strategi, mønstergjenkjenning, intuisjon, osv.
  - AlphaGo (slo Sedol i Go i 2016)
  - Basert på dype nevrale nettverk (neste generasjons KI)
- Maskiner kan aldri <u>gjenkjenne</u> objekter (håndskrift, ansikter, katt vs. hund osv.)
  - Motbevist av dype nevrale nettverk (ImageNet, 2010-tallet)

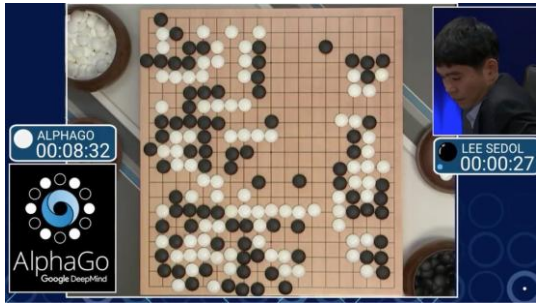

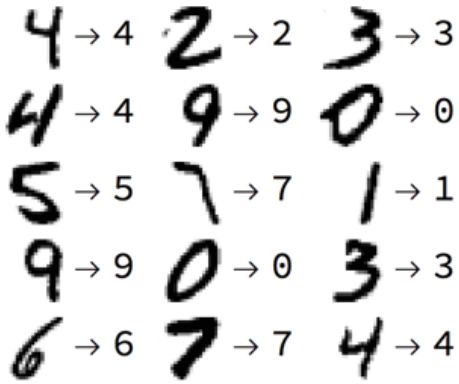

«Maskiner vil aldri klare X»

- Maskiner kan aldri oversette språk – på en måte som tar hensyn til kontekst
  - Skal «safe» oversettes til «trygg» eller «pengeskap»? Hva viser «den» til?
  - Motbevist av store språkmodeller (LLMer – ChatGPT osv.)
- Maskiner kan aldri følge instruksjoner i naturlig språk, eller generere det
  - Motbevist av språkmodeller
- Maskiner kan aldri være kreative
  - Motbevist av bilde-, musikk- og tekstgeneratorer (DALL-E, Midjourney, osv.)
- Maskiner kan aldri løse vitenskapelige gåter
  - Motbevist av AlphaFold (2018)
- Maskiner vil aldri finne nye matematiske beviser
  - Terence Tao, 7.1.26: «Erdos problem #728 was solved more or less autonomously by AI (after some feedback from an initial attempt)»

Være kraftig Norge , være pengeskap og være ledig.

Be strong Norway, be safe and be free.

can you write an essay about aristotle?

Here is an essay about Aristotle:

Aristotle: Life, Thought, and Lasting Influence

Aristotle stands as one of the most influential philosophers in Western history, shaping intellectual traditions that span more than two millennia. Born in 384 BCE in the city of Stagira in northern Greece, Aristotle's work laid foundations for philosophy, science, logic,

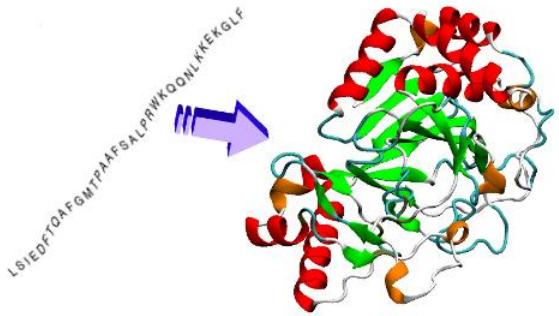

«Maskiner vil aldri klare X»

- Fortsatt kontroversielt:
  - Maskiner vil aldri kunne gjøre vitenskap helt på egen hånd
    - Velge problem, sette agenda, gjøre undersøkelser, revidere ++
  - Maskiner vil aldri gjøre helt nye oppfinnelser
  - Maskiner vil aldri kunne navigere/manipulere den fysiske verden med samme presisjon og fleksibilitet som mennesker
    - Selvkjørende biler finnes, men de kan bare kjøre (og ikke overalt)
    - Mennesker kan også husarbeid, sport, kirurgi, håndverk +++
- Diskusjon:
  - Kommer KI til å klare at dette også?
  - Er det andre ting mennesker kan som KI aldri vil klare?

«Maskiner vil aldri klare X»

- Argument for at KI vil klare alt mennesker kan (og mer!)
  - Mange ting mennesker kan, som mange trodde var umulig for KI i prinsippet, har vist seg å være mulig likevel.
  - Derfor vil alt mennesker kan være mulig for KI i prinsippet.
- Er dette et godt argument?

Hvordan klarer KI alt dette?

- Generative språkmodeller (den mest:
  - Enorm mengde tekst fra internett, bøker osv.
    - = treningsdata
  - Ut fra dette lærer modellen å forutse neste ord (eller tekstbit/*token*) i en rekke
    - Forutse fortsettelsen av en påbegynt tekst
    - Forutse svaret på et spørsmål eller respons på en instruksjon
  - En modell som kan forutse eksisterende tekst (innenfor treningsdata) kan også generere ny meningsfull tekst
    - For å forutse eksisterende tekst, lærer den mønstre som også gjelder for annen mulig tekst

Hvordan klarer KI dette?

- Mekanisme:
  - Input-tekst gjøres om til grupper av tall
  - Tallene puttes inn i et nevralt nettverk
    - Nevroner fordelt i lag med vektede forbindelser
  - I hvert lag konverteres tall til andre tall
    - I henhold til vektene
  - De siste tallene oversettes tilbake til tekst

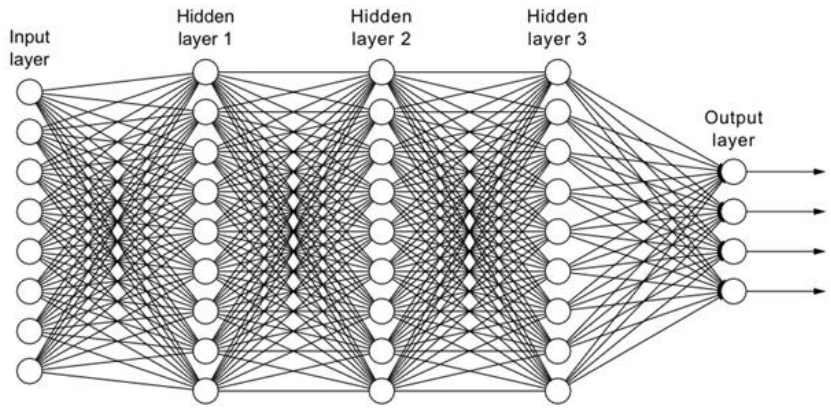

- Trening:
  - Om teksten ikke stemmer med treningsdata (*pre-training*) eller blir dårlig likt av mennesker (*post-training)* justeres vektene
  - Gjentas til vi er fornøyd med outputen.

Hvordan klarer KI dette?

- Dype nevrale nettverk (som språkmodeller) er «svarte bokser»
  - Når vi (mennesker) snakker eller skriver
    - Input → tenking, vurdering, hukommelse, sammenligning ++ → output
  - Når språkmodeller produserer tekst
    - Input → masse tall → output
    - Vi kan ikke tolke tallene, vektene osv. som «tanker» eller annet gjenkjennelig fra vårt eget hode (i hvert fall ikke direkte eller fullstendig)
    - Vi vet ikke hvilke deler av modeller (lag, vekter, nevroner) som gjør hva
- Vi vet at de fungerer
  - Og hvorfor (på overordnet nivå – pga. treningsalgoritmen)
  - Men ikke hvordan
- Litt som hjernen
  - Vi vet at den fungerer, og hvorfor (overordnet – pga. evolusjon)
  - Men i begrenset grad hvordan
    - Hva betyr det når nevroner i ulike områder fyrer av, når ulike signalstoffer blir sendt ut, osv. (**mer senere**)

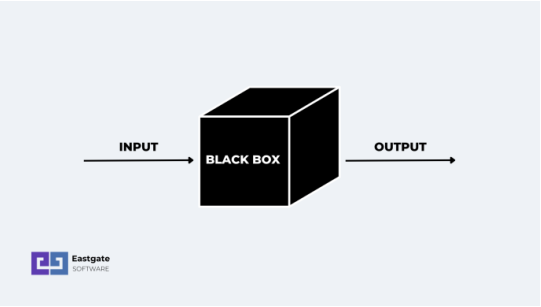

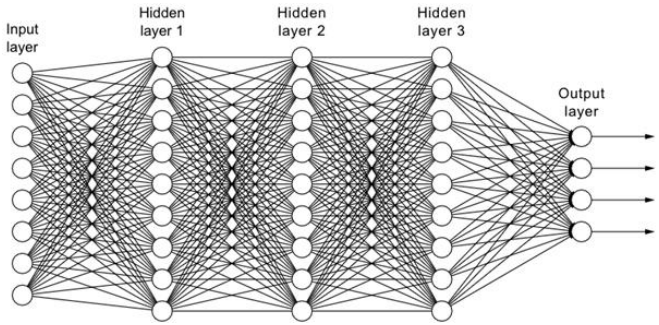

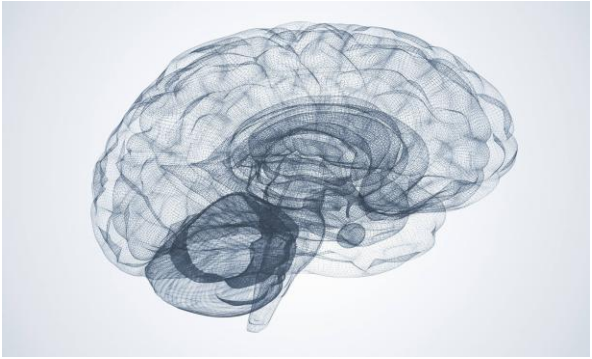

Nivåer av kunstig intelligens

- Smal kunstig intelligens
  - *Artificial narrow intelligence* (ANI)
  - Intelligens på enkelte områder
- Kunstig generell intelligens (KGI)
  - *Artificial general intelligence (AGI)*
  - Intelligens som tilsvarer menneskelig på de fleste områder
- Kunstig superintelligens (KSI)
  - *Artificial super intelligence (ASI)*
  - Intelligens som overgår menneskelig på de fleste områder
- Vanlige oppfatninger
  - Kunstig smal intelligens finnes nå
  - Kunstig generell intelligens finnes ikke nå, men er innen rekkevidde
  - Kunstig superintelligens finnes ikke nå, kanskje innen rekkevidde
- Dette reiser mange filosofiske spørsmål

Hva er filosofi?

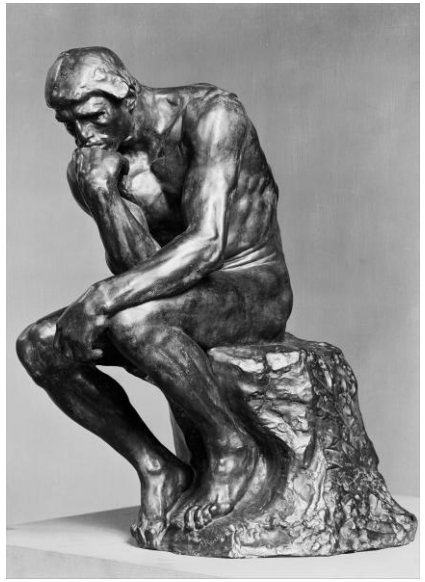

- Mulig (kort) definisjon:
  - Studiet av grunnleggende spørsmål om eksistens, mening, verdier, o.l.
- Innvending:
  - Hva med f. eks. fysikk og lingvistikk?
  - → Stiller også grunnleggende spørsmål om f. eks. eksistens og mening
- Ny definisjon:
  - Studiet av grunnleggende spørsmål om eksistens, mening, verdier, o.l.
  - Som vi ikke har en etablert <u>metode</u> for å besvare
- Filosofiske metoder
  - Logikk, argumentasjon, refleksjon, intuisjon ++
  - Leder ikke til klare svar alle er enige om
  - Ulike filosofer støtter ulike metoder (eller varianter av dem)
- → «Hva er egentlig filosofi?» og «hva er filosofisk metode?» er <u>selv filosofiske spørsmål</u>
  - Mange ulike definisjoner og meninger

Filosofiske spørsmål om KI

- Spørsmål om KI-s natur – hva det er
  - Har KI egentlig/virkelig intelligens?
    - Kan de tenke – eller bare virker det som?
      - Er de bare «stokastiske papegøyer» (Bender et al.), «glorified autocomplete», e.l.?
      - Å tenke er mer enn å statistisk forutse ord – eller noe helt annet
    - Kan de forstå?
      - Eller bare simulerer de forståelse?
    - Har ordene de bruker mening?
      - Eller er det bare tomme symboler?
  - Vi vet ikke hvordan språkmodeller (f. eks.) produserer tekst
    - Geoffrey Hinton: «to predict the next word accurately, you have to understand the sentence»
    - Gjør de det ved å tenke/forstå?
    - Eller gjør de det på en helt annen måte, som ikke bør regnes som «intelligent»?

Spørsmål om KI-s natur

- Har KI bevissthet?
  - Føles det som noe å være en KI – fra innsiden?
- Hvorfor/hvorfor ikke?
  - Hva ved hjernen er det som gir <u>oss</u> bevissthet?
  - Finnes det samme i KI?
- Tema for en rekke scifi-filmer →

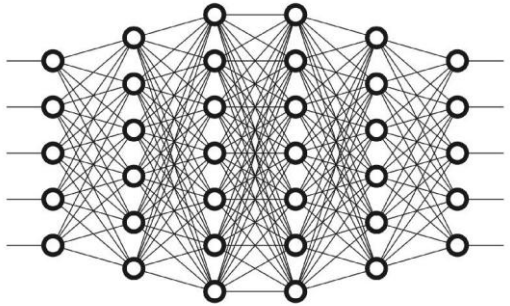

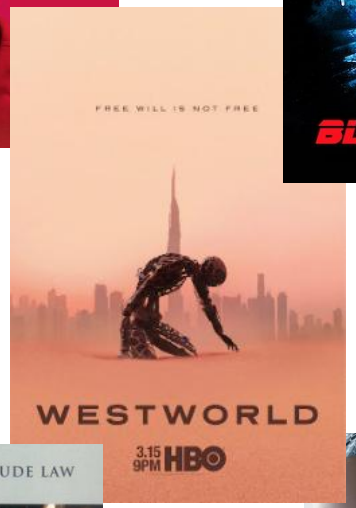

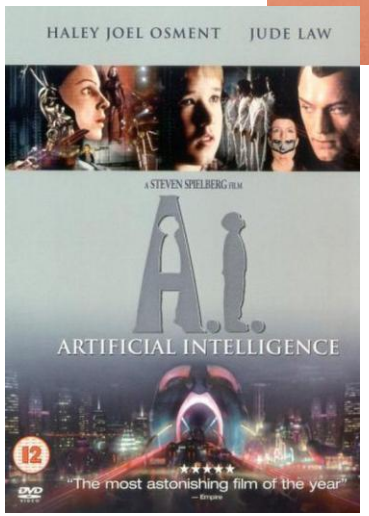

Spørsmål om KI-s natur

- Andre viktige (mulige) forskjeller?
  - Kan KI handle? (eller bare følge instruksjoner/algoritme)
  - Ha mål eller interesser?
  - Ha verdier eller moral?

Filosofiske spørsmål om KI

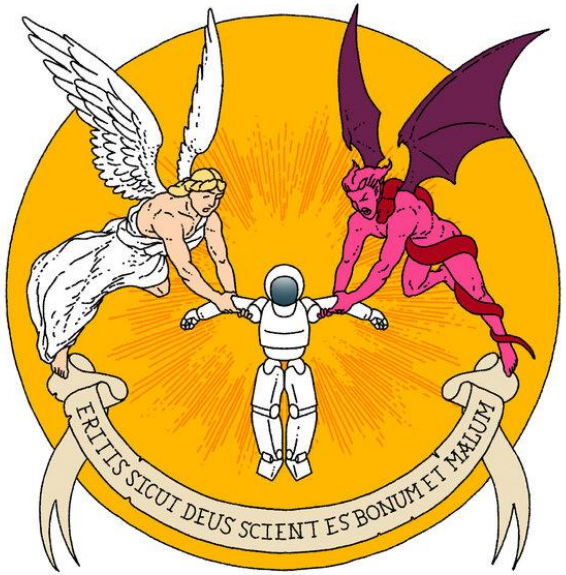

- Etikk (gren av filosofi):
  - Studiet av rett og galt, hva man bør/ikke bør gjøre, hva som har verdi (positiv og negativ)
- Etiske spørsmål om KI:
  - Hvordan bør vi oppføre oss mot KI?
  - Kan man være ond/god eller urettferdig/rettferdig mot KI? Hvordan?
- Med andre ord:
  - Kan KI ha moralsk status?

Kan KI ha moralsk status?

- Avhenger av hva vi tenker om KI-s natur
  - Om KI har bevissthet er det rimelig å tenke vi kan være onde/gode mot dem
    - Påføre smerte eller andre negative opplevelser, berøve dem for glede/positive opplevelser
  - Men er bevissthet tilstrekkelig?
    - Kanskje man trenger en viss type bevissthet?
    - Eller andre ting i tillegg?
  - Og er bevissthet nødvendig?
    - Hvis KI har mål eller interesser (men ikke bevissthet), f. eks.?

Filosofiske spørsmål om KI

- Så langt: Hvordan bør vi oppføre oss mot KI?
  - Kan KI ha moralsk status?
  - I så fall, hvordan ta hensyn til det?
- Neste spørsmål: Hvordan bør – eller vil – KI oppføre seg mot oss?

KIs oppførsel mot oss

- Hvilke verdier bør vi programmere inn i KI?
  - Selvkjørende biler
    - En stor stein har rullet ut i veien
    - Skal bilen (1) kjøre utenom og risikere å kjøre på fotgjengere eller (2) kjøre inn i steinen og risikere å drepe føreren?
  - Autonome våpen
    - I hvor stor grad skal de prioritere å skåne uskyldige?
    - I hvor stor grad bør de ta hensyn til usikkerhet?
    - Mange andre spørsmål
- Krever undersøkelse av grunnleggende etiske teorier, m.m.
  - Pliktetikk, konsekvensetikk, dydsetikk

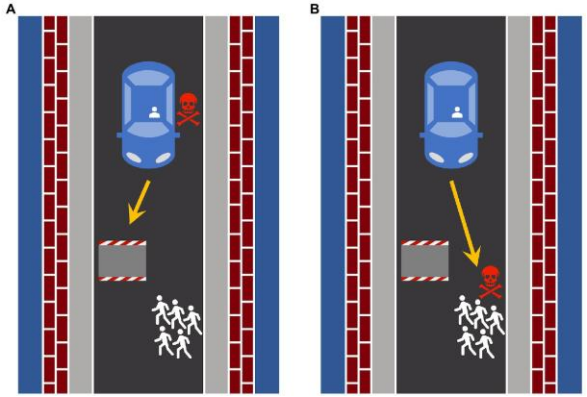

KIs oppførsel mot oss

- Men – KI kan (ofte) ikke egentlig programmeres
  - Vi setter opp en treningsprosess der den programmerer (eller konfigurerer) seg selv
  - De er svarte bokser
    - Vi vet ikke hvordan de produserer output
    - De transformerer tall – men hvorfor leder dette til noe meningsfullt og nyttig?

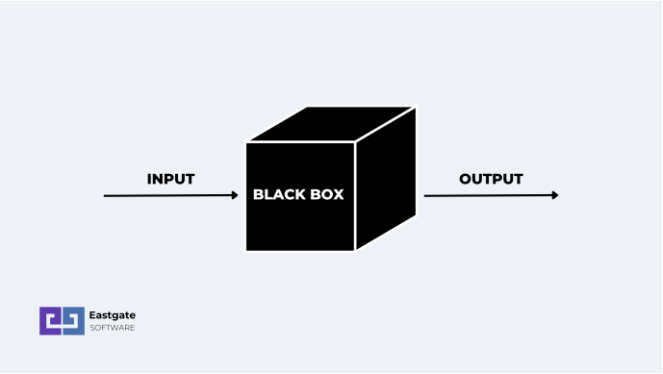

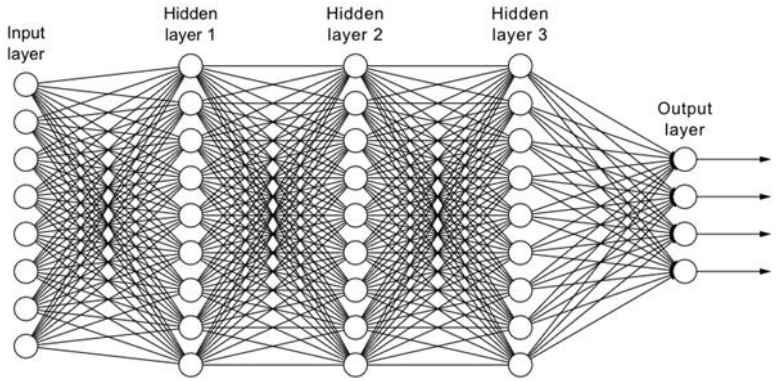

Problemet om verdimessig samstemthet (*value alignment*)

- Hvordan sikre at KI-ens verdier eller formål er samstemte (*aligned*) med våre?
  - At KI vil hjelpe mennesker, ikke skade oss, fortelle sannheten, osv.
  - Ikke skaffe makt til seg selv, forfølge mål uten hensyn til mennesker, osv.

Usamstemthet (*misalignment*)

- Også et stort scifi-tema →
- Sjakkmaskinen (Russell og Norvig)
  - En KI (på KGI-nivå) blir trent til å vinne i sjakk
  - Prøver å vinne ved å hypnotisere eller forgifte motstanderen
  - Eller drepe mennesker som den tror vil slå den av, så den kan trene og vinne mer
- Jordbærplukkeren
  - En KI blir trent opp til å plukke jordbær
  - I treningsmiljøet finnes bl.a. blåbær og mennesker – som den lærer å ikke plukke/skade
  - Ute i verden begynner den å angripe folk med store røde neser
  - Lærte ikke egentlig å pukke <u>jordbær</u>, men <u>røde avrundete 2-4 cm ting</u>

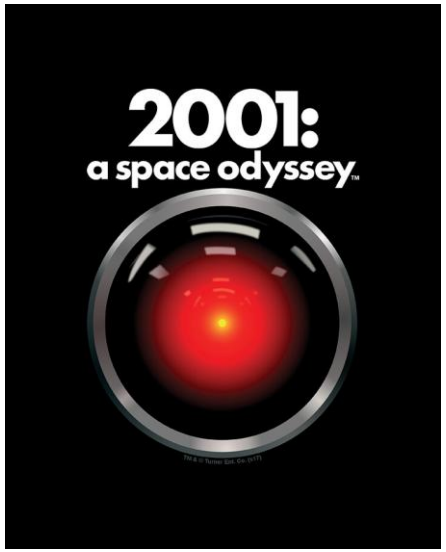

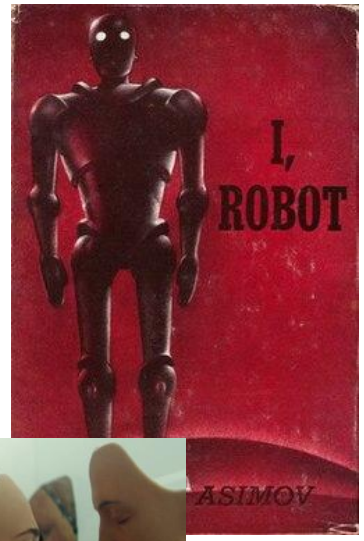

Usamstemthet → eksistensiell risiko

- Kan superintelligent KI utslette menneskeheten?
  - En superintelligent KI forstår at å utslette oss kan maksimere ressurser til å oppnå sine mål (spille sjakk, gjøre vitenskap, hva som helst)
  - Den er intelligent nok til å finne en måte å utslette oss, hindre at vi stopper den
- Mange KI-teoretikere advarer mot dette som en <u>stor fare</u> →

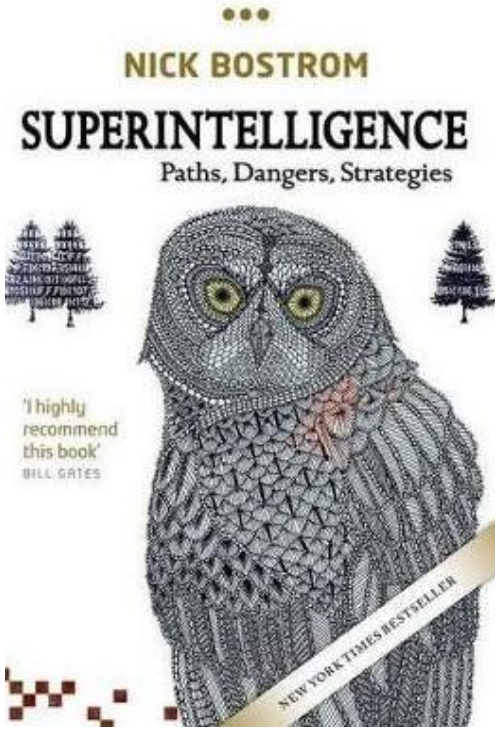

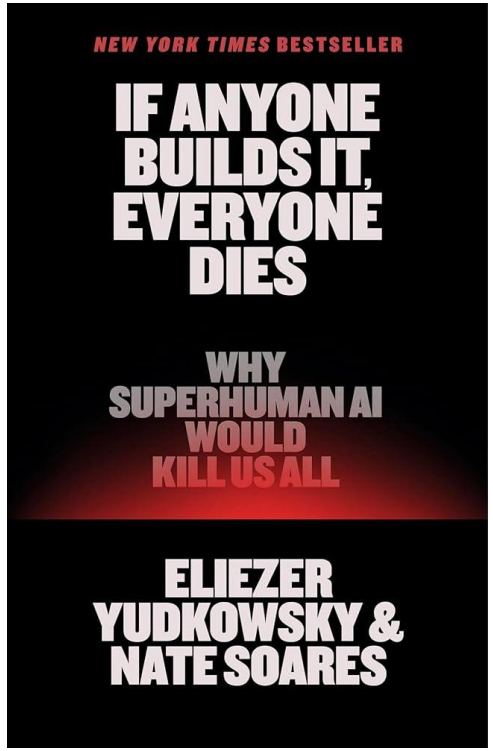

KI-utopier

- Hva om vi klarer å gjøre KI superintelligent og samstemt?
- Ingen trenger å jobbe eller løse problemer – KI fikser alt
- Hva blir da meningen med livet for oss mennesker?
  - Kreativitet?
    - Men hva om KI gjør alt kreativt arbeid bedre?
  - Være sammen?
    - Men hva skal vi snakke om eller gjøre sammen?
    - Hva om det er morsommere å være sammen med en KI?

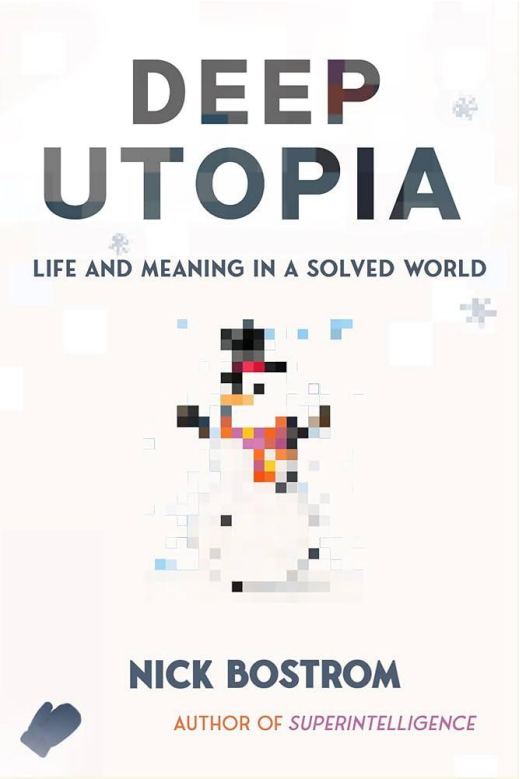

Mer nærliggende utfordringer

- Hvis KI tar over mye av økonomien, hvordan skal vi fordele ressursene våre?
  - KI-investorer sitter med all rikdom?
  - Hva skjer med resten av oss?
- Vil KI lede til like mye (eller mer) ondt som godt?
  - Miljøutfordringer
  - Feilinformasjon, propaganda, svindel
  - Svekkelse av menneskelige evner, dømmekraft, samhold, m.m.

KI og mening

- Viktige kilder til mening for mennesker:
  - Arbeid
  - Kunst/kreativitet (skape selv og oppleve andres)
  - Sosiale relasjoner
- Er KI-generert kunst like verdifull som menneskeskapt kunst?
  - KI-generelt musikk, film, bilder
  - Mye av dette hadde vi vurdert som «bra» om vi trodde det var menneskeskapt
  - Blir det mindre «bra» eller meningsfullt av å være KI-skapt? Hvorfor?
- Er «sosiale» relasjoner med KI meningsfulle?
  - KI-kjærester og -venner allerede utbredt
  - Mange ser på dette som negativt, men hvorfor?

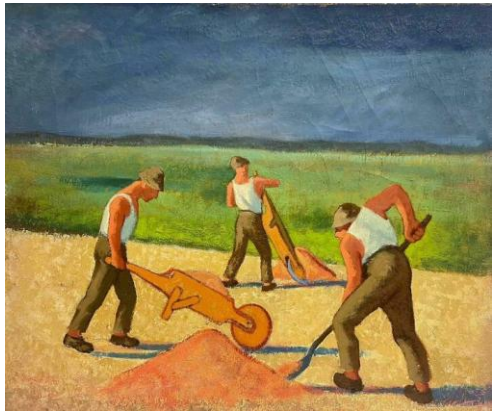

Oversikt over emnet

- 16 forelesninger fordelt over 8 dager
  - 2 per dag, lunsjpause i mellom
  - Ulike forelesere
- 2 obligatoriske innleveringer
  - Essay på opptil 800 ord
  - Vurderes som bestått/ikke bestått – ved ikke bestått gis ett nytt forsøk
  - Må bestå for å kunne ta eksamen
- Skriftlig skoleeksamen (4 timer)
  - Kan bli spørsmål fra hele pensum
  - (Litt) mer informasjon kommer mot slutten av undervisningen
  - Viktigste forberedelse: lese, forstå, reflektere over pensum
    - Les pensum, ikke KI-genererte sammendrag!
    - Flere anbefalinger om bruk av KI i studiene ligger på Canvas (lenke fra forsiden).

Canvas

- Her finnes den viktigste informasjonen dere trenger
- Les gjennom hele forsiden
- Følg med på kunngjøringer og meldinger
- Følg leseplanen (på forsiden) – les pensum <u>før</u> forelesning
  - Pensum ligger under Filer/pensum/[egen mappe for hver foreleser]
- Lysbilder og oversiktsark blir lagt ut <u>etter</u> forelesninger

Språk

- Mesteparten av pensum er på engelsk
- Slå opp alle ord dere ikke forstår – det lønner seg!
  - Ordnett.no (innlogging via Feide/studentkonto)
    - Fungerer dårligere på tekniske fagord
  - ChatGPT o.l. kan forklare ord
- Rekk opp hånden om jeg (eller andre forelesere) bruker et ord du ikke forstår
  - Du er ofte ikke den eneste som lurer

Kunstig intelligens og bevissthet

Kunstig intelligens og filosofi (FIL1010), INN

Hedda Hassel Mørch

23.01.2026

Bevissthet

- Kan kunstig intelligens ha bevissthet?
  - Har (noen) KI det allerede nå?
  - Vil de få det snart – eller med dagens teknologi?
  - Kan de få det med noen teknologi – eller er bevissthet kun biologisk?

I dag og neste gang

- Hva mener vi med «bevissthet»?
- Problemet om andre sinn
  - Hvordan vet vi at andre mennesker har bevissthet?
- Problemet om KI-sinn
  - Hvordan vet vi om KI har bevissthet?
- Kan vitenskapen fortelle oss om KI har bevissthet?
  - *The hard problem of consciousness*
  - Bekreftelsesproblemet
  - Generaliseringsproblemet
- Kan filosofien fortelle oss om KI har bevissthet?
  - Filosofiske teorier om bevissthet – og argumenter for og mot
  - Hva de sier om KI-bevissthet
    - I kombinasjon med vitenskapelige teorier
  - Andre filosofiske tester
    - Turing-testen, ACT-testen (Schneider), m. fl.

Hva mener vi med «bevissthet»?

- Det du har når du er våken eller drømmer – og mister når du går inn i drømmeløs søvn, narkose, koma
  - Men hva er det?
- At det føles eller oppleves som noe å være deg
  - Å ha en form for subjektiv opplevelse

Hva mener vi med «bevissthet»?

- <u>Eksempler</u> på subjektiv opplevelse
  - Se en farge
  - Føle sult
  - Føle smerte (eller glede)
- Subjektiv opplevelse = det alle disse har til felles; er eksempler på

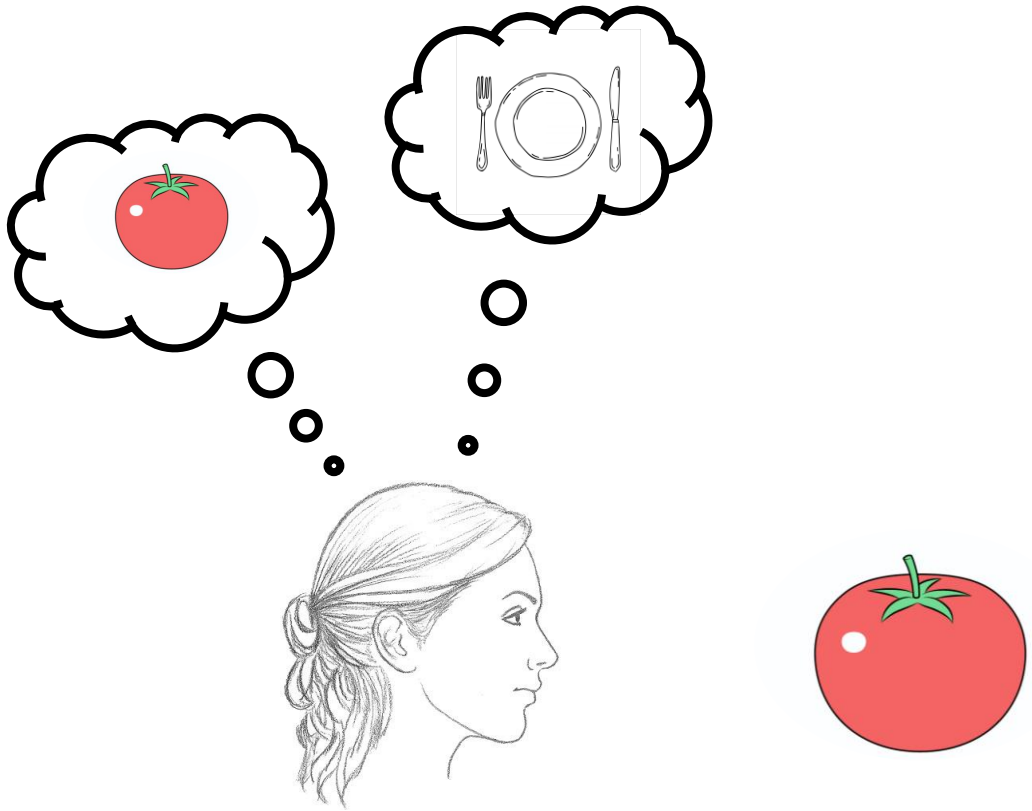

Hva mener vi med «bevissthet»?

- Denne definisjonen stammer fra Thomas Nagel:
  - «Fundamentally an organism has conscious mental states if and only if there is something that it is like to be that organism–something it is like *for* the organism.»
  - «We may call this the subjective character of experience.»
    - Fra *What is it like to be a bat? 1974*
- Har blitt standard definisjon i filosofi
- Norsk oversettelse:
  - «det føles/oppleves som noe å være et vesen – for vesenet»

Andre betydninger

- Å ta inn <u>informasjon</u> om miljøet og seg selv – og reagere på informasjonen
  - Hvis man mister dette (midlertidig) kalles man «bevisstløs»
- Å kunne <u>tenke</u>, resonnere (≈ ha intelligens)
  - <u>Behandle</u> informasjon om seg selv og miljøet
- Å kunne <u>reflektere</u> over seg selv, det man tenker/sanser
  - → Kan også kalles <u>selv-bevissthet</u>
- Alt dette kan forstås som <u>funksjoner</u> eller <u>evner</u>
  - Noe man <u>gjør</u> eller <u>kan gjøre</u>

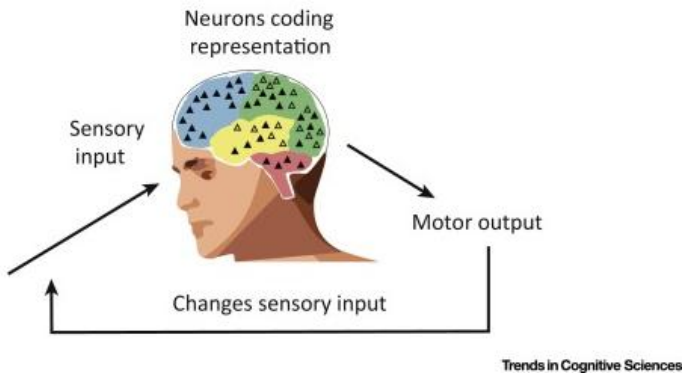

En viktig distinksjon

- Funksjonell bevissthet = evner eller funksjoner et vesen kan ha
  - Noe de gjør/kan gjøre
  - Ta inn/reagere på informasjon, tenke/resonnere, selv-refleksjon, osv.
- Fenomenal bevissthet = subjektiv opplevelse, at det føles/oppleves som noe
  - Noe som skjer/en måte man er – ikke (bare) noe man gjør
  - Fenomenal opplevelser/tilstander kalles også kvalia
- Ulike begreper
  - Man kan tenke seg funksjonell bevissthet uten fenomenal bevissthet
    - Robotstøvsugere, kunstig intelligens
  - Man kan tenke seg fenomenal bevissthet uten funksjonell bevissthet
    - En «bevisstløs» (besvimt, sovende, i koma) person kan ikke ta inn/reagere på informasjon om miljøet – men kan fortsatt hallusinere eller drømme
    - Dyr og nyfødte barn
      - Mye lavere intelligens enn vokse mennesker – har fortsatt (antar de fleste) subjektiv opplevelse
- Er det ulike egenskaper/fenomener?
  - Stor debatt! Dette kommer vi tilbake til **senere**

Bevissthet vs. sinn og sjel

- Sinnet (*mind*)
  - Det som <u>har</u> bevissthet (eller bevisstheten er en del av)
  - Men ikke <u>alltid</u> eller <u>fullstendig</u> bevisst
    - I dyp søvn mister vi <u>bevisstheten</u>, men <u>ikke sinnet</u>
    - Mange deler av sinnet er <u>ubevisste/automatiske</u>
- Det mentale
  - Det som har med sinnet å gjøre
  - Mental tilstander (*mental states*), mentale prosesser, osv.
- Sjel – mange betydninger:
  - Det samme som sinnet
  - Det samme som sinnet + <u>udødelig</u>, <u>immateriell</u>
    - Kan forlate kroppen, komme til himmelen, bli gjenfødt, osv..
  - Menneskets moralske kjerne, integritet
    - «Å selge sjelen sin»
  - Det som gjør deg unik, kreativ, etc.

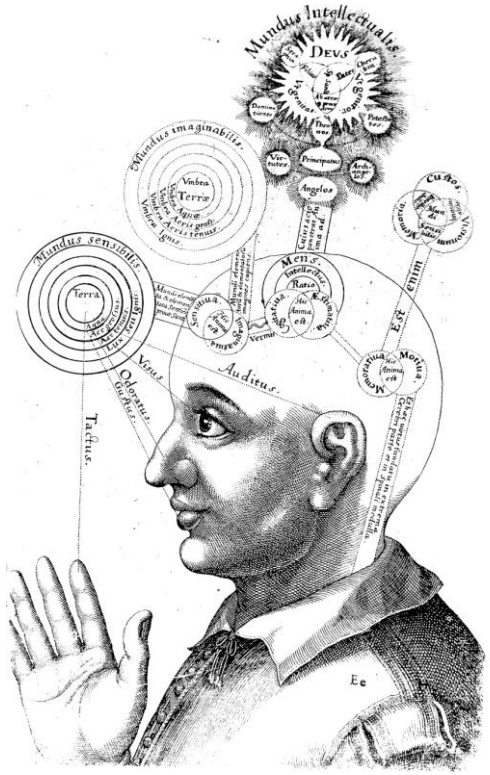

Hvordan vet vi at andre mennesker har bevissthet?

- Vi føler oss helt sikre på at andre mennesker (og i hvert fall noen dyr) har bevissthet
  - I våken tilstand, etter et visst fosterutviklingsstadium
- Men hvordan vet vi egentlig det?
- Funksjonell bevissthet
  - Evner og funksjoner kan observeres (i prinsippet)
    - Består av ytre adferd + indre fysiologiske mekanismer
- Fenomenal bevissthet
  - Fenomenal bevissthet er privat
  - Kan ikke direkte observeres – bortsett fra i ditt eget tilfelle!
    - Andres opplevelser observeres kun indirekte via tegn
      - Adferd, språk, ansiktsuttrykk, osv. tyder på (f.eks.) smerteføelelse
      - Men vi observerer ikke selve smerteføelelsen

- Fra nå: med «bevissthet» menes «fenomenal bevissthet» – med mindre annet presiseres!

Problemet om andre sinn

- Vi kan ikke vite (helt sikkert) at noen andre har bevissthet
    - Eller et sinn – men bevissthet er den delen av sinnet vi bryr oss mest om!
  - Vi kan forestille oss at andre opplever verden helt annerledes
    - Ser grønt når du ser rødt, osv.
  - Vi kan forestille oss alle andre er «zombier»
    - Fysisk tilsvarende deg men – men uten noe subjektivt «indre liv»
  - Solipsisme (om bevissthet) = jeg er det eneste bevisste vesenet
    - Kan ikke utelukkes
- Se Nagel: «Andre sinn»

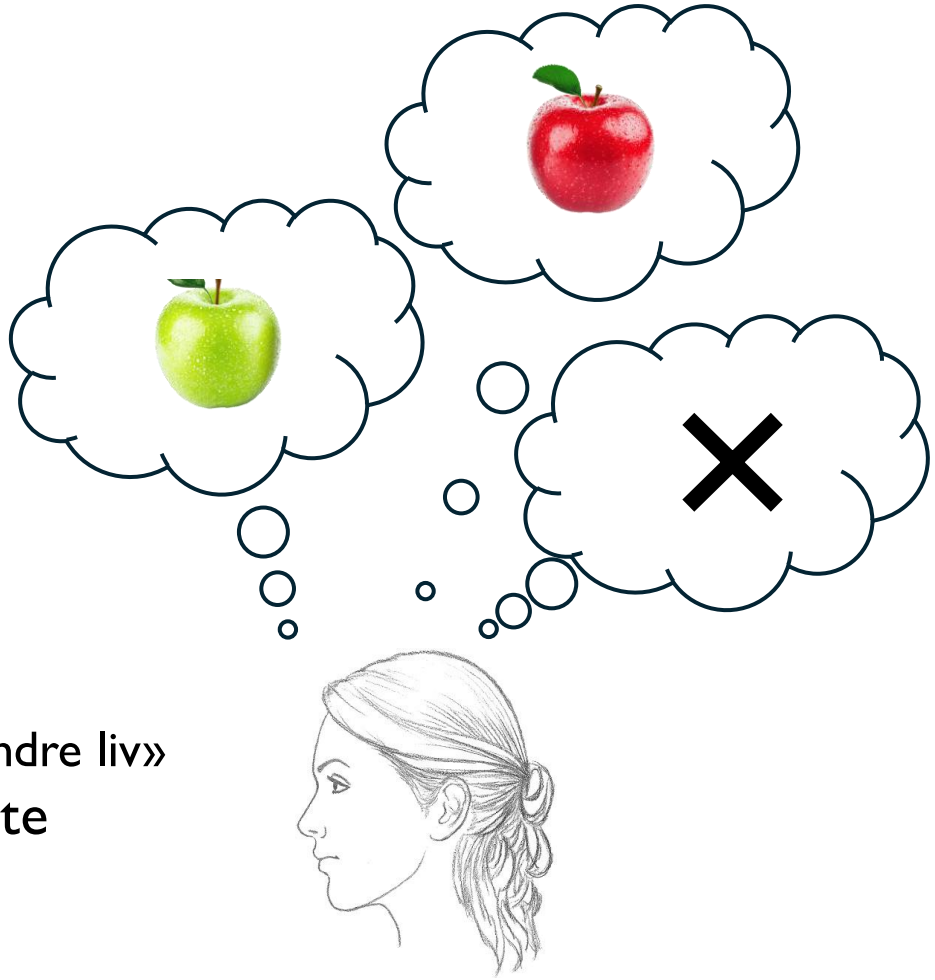

Problemet om andre sinn

- Naturlig svar:
  - Hvis andre ligner meg på alle fysiske måter:
    - samme adferd
    - samme indre fysiologi og hjernetilstand
    - er i samme fysiske situasjon
  - Så må de ha samme subjektive opplevelser som meg
- Innvending (Nagel)
  - Du vet at dine subjektive opplevelser korrelerer med din adferd, fysiologi og situasjon
  - Men det betyr ikke at korrelasjonen holder generelt – for andre også!
- Innvending 2:
  - Ingen andre er 100% fysisk like deg – det er alltid noen forskjeller

Diskusjon

- Hvordan løser vi problemet om andre sinn?
  - Hvordan vet vi at andre mennesker har bevissthet?
  - Kan samme «metode» fortelle oss hvorvidt KI har bevissthet?

Problemet om andre sinn

- Typisk videre svar
  - Kanskje ikke <u>sikkert</u>, men fortsatt <u>veldig rimelig,</u> å anta at fysisk likhet → mental likhet
    - Og at <u>små</u> fysiske forskjeller ikke betyr noe
  - Ingenting er helt sikkert uansett
    - Vi vet ikke sikkert at vi ikke lever i the Matrix, at alle minnene våre ikke er falske, osv.
  - <u>Skeptisisme</u> kan aldri motbevises – men det betyr ikke at vi må akseptere det
    - Skeptisisme = vi kan ikke vite noen ting <u>helt sikkert</u>
  - Solipsisme (om bevissthet/andre sinn) er en form for skeptisisme
- Vi vet at andre mennesker har bevissthet i henhold til <u>vanlig standard for kunnskap</u>

Problemet med KI-sinn

- KI-er er like oss på <u>noen</u> måter, men ulike på andre
  - Delvis like funksjoner og evner
    - Kan bruke språk, spille sjakk, gjenkjenne objekter (alt fra tidligere liste)
    - På lignende måte (mønstergjenkjenning, ikke rå regnekraft)
    - Kan bli enda likere! (om vi nærmer oss KGI)
  - Ulik fysisk sammensetning og arkitektur
    - Kjører på maskiner laget av silikon – ikke organisk materiale
    - Transistorer koblet sammen på en annen måte enn nevroner
- Hvor mye likhet er nødvendig? Hvilke typer?
- → Løsningen på problemet om andre <u>menneske</u>sinn fungerer ikke for problemet om <u>KI</u>-sinn

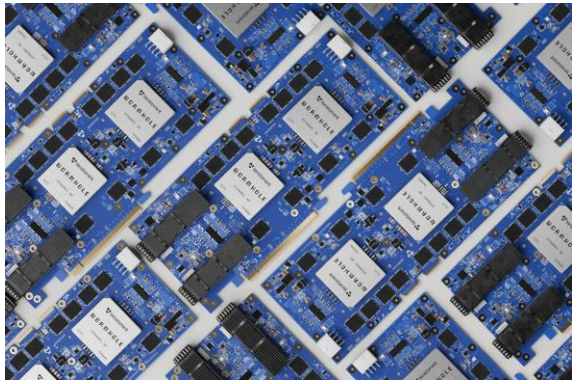

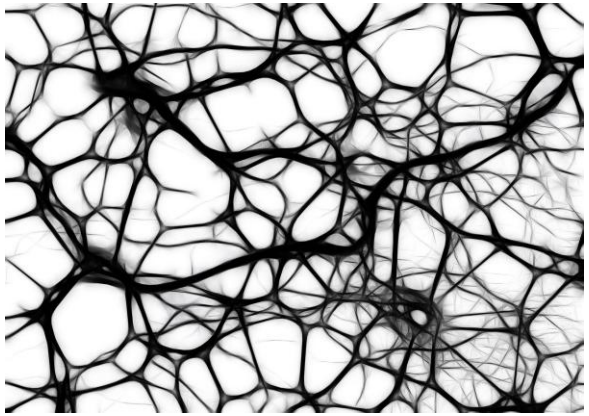

Hva sier vitenskapen?

- Det gjøres mye vitenskapelig forskning på bevissthet
  - Nevrovitenskap, kognitiv vitenskap, m.m.
- Flere store teorier
  - «Global workspace»-teorien
    - Bevissthet er kringkasting av informasjon i et «global workspace»
      - Struktur som samler ulike informasjonskilder via sentralt knutepunkt
  - Integrert informasjonsteori
    - Bevissthet er en bestemt type kompleksitet vi finnes høye grader av i hjernen
  - Mange flere – og mer om disse **senere**
- Kan vitenskapen fortelle oss om KI har bevissthet?
  - → Vitenskapen har noen viktige <u>begrensinger</u>

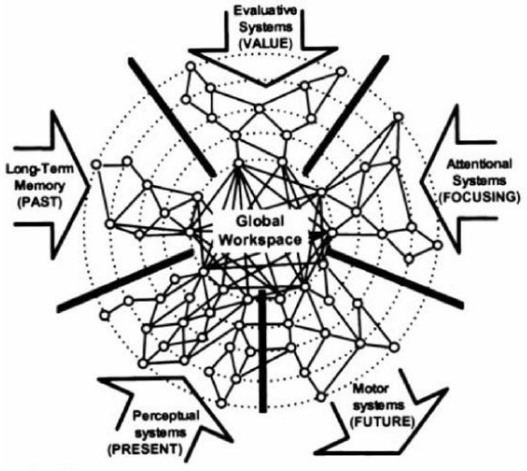

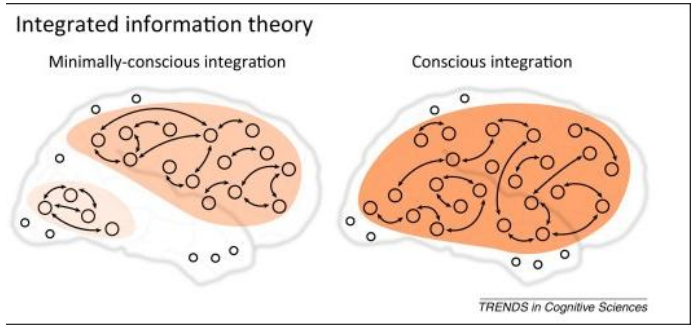

The hard problem

- David Chalmers:
  - Vitenskapen kan bare løse <u>de enkle problemene</u> (*the easy problems*) om bevissthet
  - Kan ikke løse <u>det vanskelige problemet</u> (*the hard problem*)

The easy problems

- De enkle problemene
  - Hvordan kan bevisste vesener utføre funksjoner som å:
    - Registrere informasjon om miljøet og seg selv? Handle intelligent?
    - Styre oppmerksomheten?
- Handler om <u>funksjonell</u> bevissthet – eller <u>evner og funksjoner</u> forbundet med bevissthet
- Vi vet hvordan vi forklarer funksjoner og strukturer
  - Ved å finne <u>mekanismer</u> som utfører funksjonene
  - Ved å finne <u>bestanddeler</u> som utgjør strukturen

Forklaringer på funksjoner/strukturer

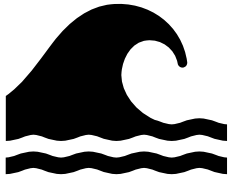

- Vann
  - Funksjon/struktur: stoff som er gjennomsiktig, flytende, m.m.
  - Mekanisme/bestanddeler: H_2O-molekyler bundet sammen på en sånn måte at de slipper gjennom lys; sklir lett av hverandre, etc.

- Hjernen
  - Funksjon: behandler informasjon
  - Mekanisme:
    - Hjernen er lagd av nevroner.
    - Nevroner er som transistorer (på/av = avfyre/ikke avfyre)
    - Derfor prosesserer hjernen informasjon på samme måte som en datamaskin.
  - Funksjon 2: kan få kroppen til å bevege seg – f. eks. bena mine
  - Mekanisme:
    - Nevroner i hjernen er koblet til nevroner i bena mine som er koblet til musklene.
    - Et elektrisk signal kan derfor sendes fra nevroner i hjernen til musklene i bena.
    - Her vil elektrisiteten få musklene til å trekke seg sammen på en måte som skaper riktig bevegelse.

The hard problem

- «Hvorfor er bevisstheten funksjoner ledsaget av opplevelse?»
- «Hvorfor føles det som noe å utføre funksjoner sånn som persepsjon, informasjonsprosessering, etc?»
- «Det er bred enighet om at opplevelse oppstår fra en fysisk basis, men vi har ingen god forklaring på hvorfor eller hvordan den oppstår.»
- «Hvorfor gir fysiske prosessering opphav til et rikt indre liv i det hele tatt? Det virker objektivt urimelig at det skal gjøre det, men likevel gjør det det.»
- «Nevrovitenskap og kognitiv vitenskaps vanlige metoder er ikke tilstrekkelige [til å løse dette problemet]»
- → Handler om fenomenal bevissthet

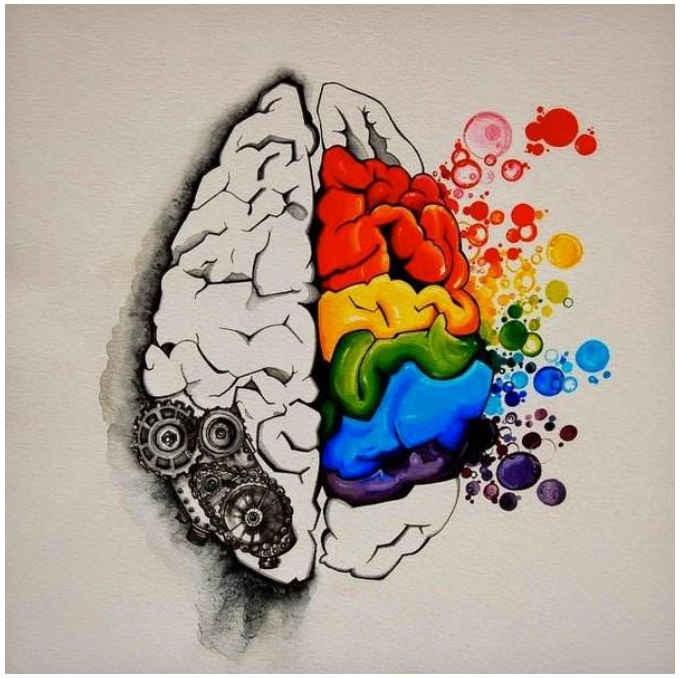

Nevrovitenskapelige teorier og det vanskelige problemet

- Crick og Koch (tidlig teori): bevissthet krever 35-75 hertz bølger i frontallappen.
- Chalmers:
  - Dette kan forklare hvordan hjernen integrerer informasjon, hvordan minner formes, m.m. (*easy problems!)*
  - Men hvorfor er 35-75 hertz bølger ledsaget av opplevelse? Ikke forklart!
- Bevissthet krever kringkasting av informasjon i et «global workspace»
- Chalmers:
  - Dette kan forklare kognitiv tilgang m.m. (*easy problems!)*
  - Men hvorfor er global kringkasting ledsaget av opplevelse? Ikke forklart!

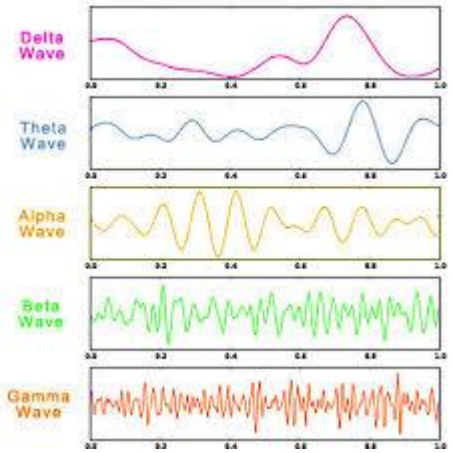

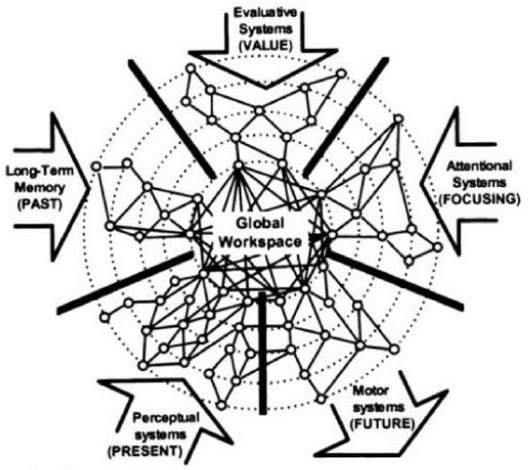

Korrelasjon vs. forklaring

- Chalmers:
  - «For any physical process we specify there will be an unanswered question: Why should this process give rise to experience?»
- Nevrovitenskaplige teorier gir oss bare korrelasjoner mellom opplevelse og nevrale/fysiske prosesser
  - Korrelasjon mellom A og B = hver gang A forekommer, forekommer også B
    - Eller vanligvis, eller med X% sjanse
  - Bevisthetens nevrale (eller fysiske) korrelater
    - Forkortet NCC (*neural correlate of consciousness*) eller PCC (*physical correlate*)
- Forklarer ikke hvorfor korrelasjonene holder.
- For en slik forklaring trenger vi også filosofi

KI og «the hard problem»

- For å finne ut om KI har bevissthet, trenger vi egentlig bare korrelasjoner
  - Vi trenger ikke <u>forklare</u> dem – løse «the hard problem»
- Bevissthet krever 35-75 hertz bølger i frontallappen
  - → KI har bevissthet hvis de også har slike bølger
- Bevissthet er korrelert med kringkasting av informasjon i et «global workspace»
  - → KI har bevissthet hvis de også har en global workspace

Bekreftelsesproblemet

- Men slike korrelasjoner er vanskelig å bekrefte eksperimentelt
- En korrelasjon mellom bevissthet og hjernetilstand type X må bekreftes ved å observere dem samtidig
- Bevissthet kan ikke direkte observeres
  - Bare via rapporter og andre tegn
  - Folk kan ha bevissthet uten å kunne rapportere det
    - I drømme eller koma
    - Hvis man var bevisst i drømme eller koma, kan man ha glemt det når man våkner opp
  - Rapporter kan være upresise eller gale
- Hjernens indre kan ikke observeres presist
  - Hjerneskanningsteknikker gir begrensede detaljer, bare noen typer informasjon

Generaliseringsproblemet

- Hvordan generalisere korrelasjoner hos mennesker til KI (eller dyr)?
  - Vil aldri finne det samme korrelatet, bare noe lignende
  - Hvor mye likhet? Og hvilke typer?
    - Samme problemet vi startet med – består i lys av vitenskap
- Om bevissthet hos mennesker korrelerer med 35-75hz hjernebølger
  - Hva tilsvarer dette hos KI?
    - Finnes det «bølger» i en KI? Av lignende nok type?
    - Holder det med X-bølger i «noe» – eller må det være bølger av nevronaktivitet?
- Om bevissthet hos mennesker korrelerer med aktivering av «global workspace»
  - Hva tilsvarer dette hos KI?
  - Kan «arbeidsrommet» være laget av noe annet enn nevroner?

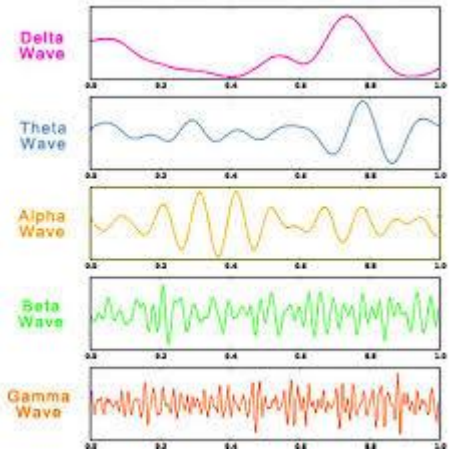

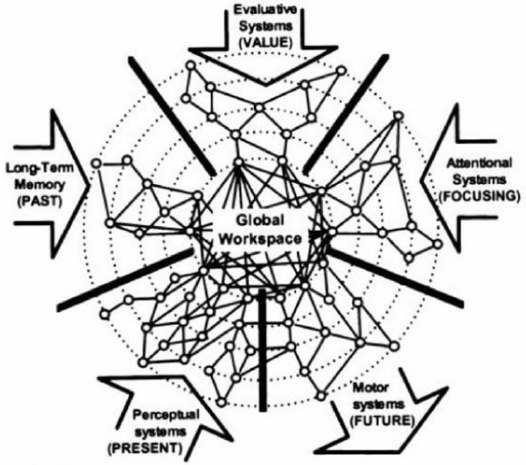

Hva sier filosofien?

- Når etablerte metoder feiler, havner man i filosofi (som sagt)
- Kan filosofi hjelpe oss å finne ut om KI har bevissthet?
  - Alene, eller i samarbeid med vitenskap?
- I dag:
  - Filosofiske teorier om bevissthet
    - Fysikalisme og ikke-fysikalisme
    - Funksjonalisme og ikke-funksjonalisme
- Neste gang:
  - Argumenter for og mot funksjonalisme
  - <u>Hvilke</u> fysiske egenskaper eller funksjoner er nødvendige for bevissthet?
    - I følge ulike vitenskapelige teorier
    - Har KI disse – eller kan de (snart) få dem?
  - Andre tester for bevissthet

Filosofiske teorier om bevissthet

- Viktige skiller:
  - Fysikalisme vs. ikke-fysikalisme
  - Funksjonalisme vs. ikke-funksjonalisme

Fysikalisme

- Definisjon av fysikalisme
  - Alt er fysisk – inkludert bevissthet
  - Tidligere kjent som materialisme
    - Men den fysiske verden består ikke bare (eller fundamentalt?) materie; heller av felt, krefter, partikler uten masse, osv.
  - Fysisk = fullstendig beskrevet av fysikk
    - Mer presist: en fremtidig, komplett fysikk i kontinuitet med vår
      - Den fysikk-baserte definisjonen
  - → Bevissthet er bare 35-75hz hjernebølger, eller aktivering av en global workspace struktur, e.l
  - → Smerte er bare C-fiber som fyrer av, lykke er bare serotonin, e.l.
- Mer presis definisjon
  - Alt er fysisk eller fysisk konstituert
    - Fysisk = fullstendig beskrevet av (fremtidig, fullført) fysikk
    - Fysisk konstituert = laget av stoff/bestanddeler som er fullstendig beskrevet av fysikk
  - Vi bruker «fysisk» på en måte som inkluderer «fysisk konstituert»

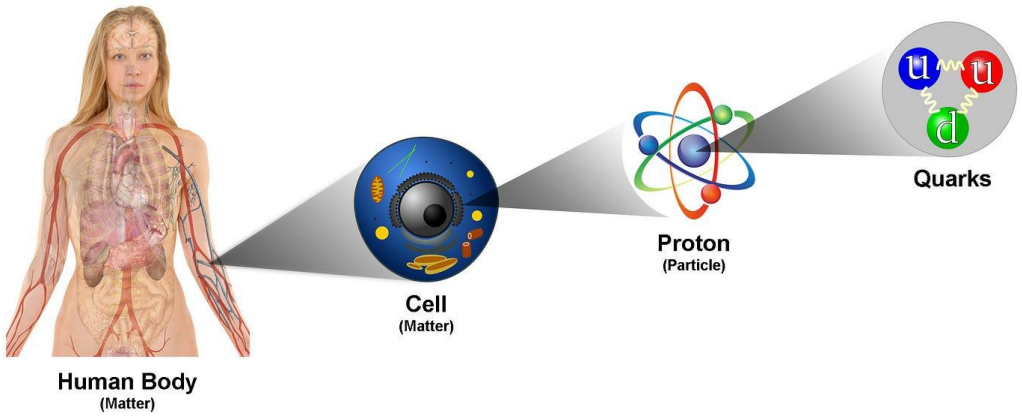

Ikke-fysikalisme

- Dualisme
  - Bevissthet er ikke fysisk
  - Men koblet til den fysiske verden (typisk hjernen) via psykofysiske lover (eller kausalitet = via årsak og virkning)
    - Fysiske lover: tyngdeloven, de elektromagnetiske lovene, osv.
    - Psykofysiske lover: hvis hjernen er i tilstand X til vil det oppstå bevissthet (av type Y)
      - Hvis hjernen har 35-75hz bølger, så vil det forårsake bevissthet
      - Hvis C-fiber fyrer av, så vil det forårsake oppstå smerte
- Panpsykisme
  - Bevissthet er ikke fysisk
  - «Innsiden» av all fysisk materie
    - Fysikken forteller oss bare om materiens «utside»
  - Fundamentale partikler har fundamental, enkel bevissthet
  - Mental kombinasjon
    - I hjernen, men (antagelig) ikke stoler og bord, settes enkel bevissthet sammen til kompleks bevissthet som vår
    - 35-75hz bølger, «global worskpace»-aktivering, e.l. korrelerer med kombinasjon, ikke bevissthet som sådan

Dualisme

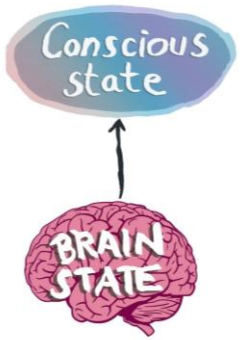

Fysikalisme

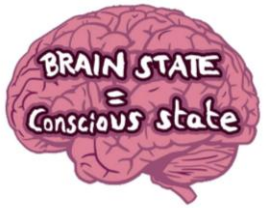

Panpsykisme

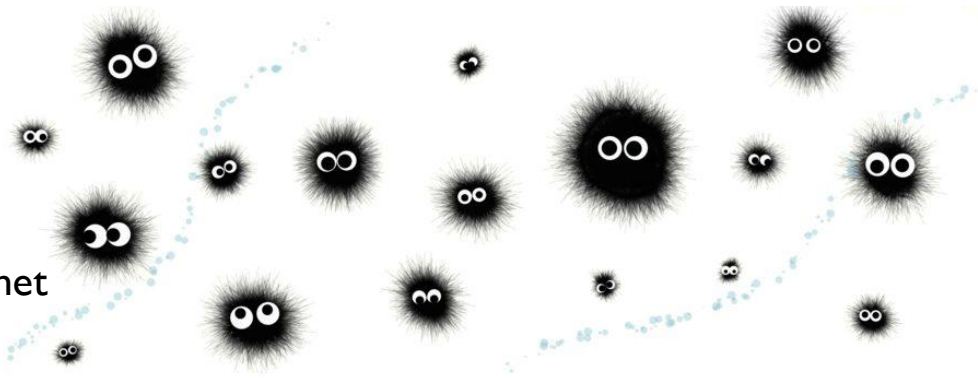

Håndsopprekning

- Fysikalisme eller ikke-fysikalisme?

Argumenter for fysikalisme

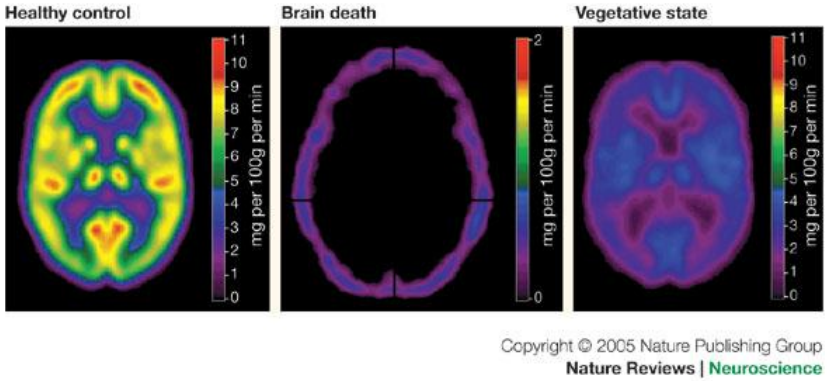

- Argumenter fra hjerne/bevissthets-korrelasjoner
  - Bevissthet korrelerer med hjernetilstander
    - Ingen bevissthet uten hjerne
    - Hver gang vi er i en viss type bevissthetstilstand er vi også i en viss type hjernetilstand
      - Hver gang vi føler oss lykkelige har hjernen mye serotonin
      - Hver gang vi ser rødt har vi en viss type aktivitet i synsbarken
    - Hver gang vi har bevissthet i det hele tatt har vi (antar vi) én mer generell type hjernetilstand
      - Global workspace-aktivering, høy integrert informasjon, 30-75hz bølger...
    - Vi kan påvirke bevisstheten ved å påvirke hjernen
      - Medisiner, rusmidler, hjerneskader, osv.
  - Den beste forklaringen på korrelasjonene er at bevissthet er fysisk
    - Bevissthetstilstander bare er hjernetilstandene de korrelerer med
  - Med andre ord:
    - Fysikalisme er den åpenbare løsningen på *the hard problem*

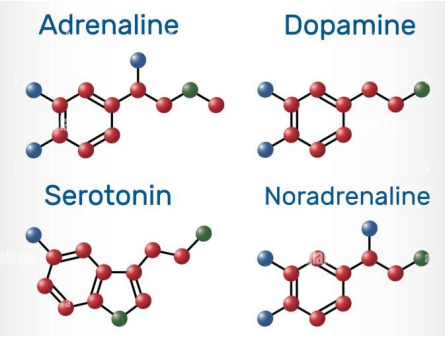

Argumenter for fysikalisme

- Argumentet fra tidligere vitenskapelige suksesser
  - Andre fenomener tidligere ansett som mystiske/fysiske uforklarlige har blitt fysisk forklart ett etter ett:
    - Stjerner, været, sykdommer, liv
    - Til en viss grad <u>funksjonell</u> bevissthet
      - Særlig via informatikk/beregningsvitenskap (*computer science*) og nevrofysiologi – nylig utvikling
  - Derfor vil sannsynligvis <u>fenomenal</u> bevissthet også bli fysisk forklart
    - Selv om det fremstår som mystisk og uforklarlig nå
- Det kausale argumentet
  - Viktigst – men vanskeligst! Les om det i boken.

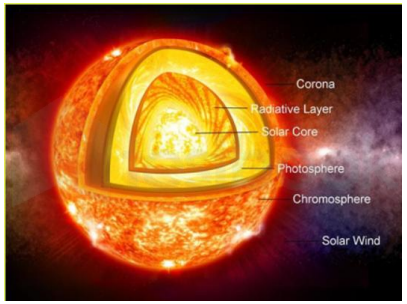

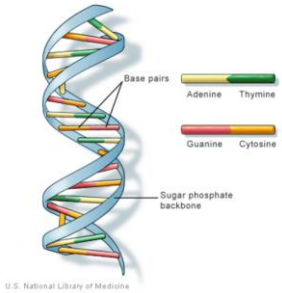

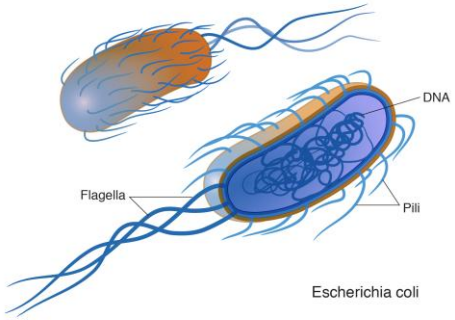

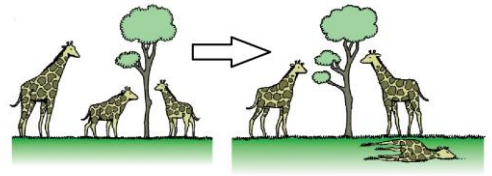

Argumenter mot fysikalisme

- Tankeeksperiment
  - Mary er en genial nevrovitenskapskvinne.
  - Oppvokst i et svart/hvitt rom – aldri sett farger – men har lært alle fysiske fakta om farger.
    - Fra fysikk, fysiologi, og andre relevante vitenskapelige teorier.
  - En dag blir hun sluppet ut av rommet, ser en rød rose.
  - Lærer noe nytt: hvordan det oppleves å se fargen rød.
- Kunnskapsargumentet
  1. Mary kjenner alle fysiske fakta
  2. Mary kjenner ikke alle fakta om bevissthet
     - Hvordan det oppleves å se rødt

  ---

  3. **Fakta om bevissthet er ikke fysiske fakta**
- Kobling til problemet om andre sinn
  1. Bevissthet er <u>privat</u> – kan bare kjennes ved å <u>ha</u> det selv
  2. Fysiske fakta er <u>ikke private</u>
  3. Derfor er bevissthet ikke fysisk?

Frank Jackson

Argumenter mot fysikalisme

- Forklaringsargumentet
  1. Vitenskapen kan ikke forklare bevissthet.
     - Kan ikke løse the hard problem
  2. Hvis vitenskapen ikke kan forklare bevissthet, så er bevissthet ikke fysisk.

---

  3. **Bevissthet er ikke fysisk.**
- Mer presist
  - Vitenskapen kan ikke gi en reduktiv forklaring av bevissthet
  - Se Chalmers: «Facing up to the problem of consciousness» for detaljer
- Også en kritikk av:
  - Argumentet for fysikalisme fra tidligere vitenskapelige suksesser
    - Alle fenomener som tidligere er forklart er funksjonelle/strukturelle
    - Bevissthet er ikke (rent) funksjonelt/strukturelt – kan derfor ikke generalisere!
  - Argumentet fra hjerne/bevissthets-korrelasjoner
    - Før vi kan si at bevissthet bare er en hjernetilstand, må vi gi en fysisk forklaring på det.

Varianter av fysikalisme

- Identitetsteori
  - Også kjent som biologisk naturalisme
  - Bevissthet er identisk med/konstituert av konkrete nevrale/biologiske prosesser
    - Smerte er bare C-fiber som fyrer av
      - Hypotetisk men standard eksempel
    - Å se rødt er bare en type nevral aktivitet i synsbarken
    - Lykke er bare en høyt serotoninnivå
    - Bevissthet generelt er bare nevral aktivitet eller struktur med et visst kjennetegn
  - → Bevissthet er substrat-avhengig
    - Må være laget av et spesifikt stoff/materiale: biologisk

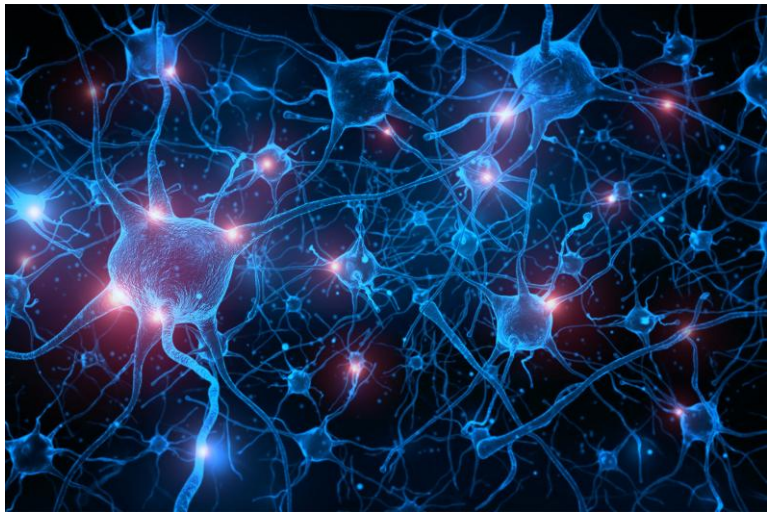

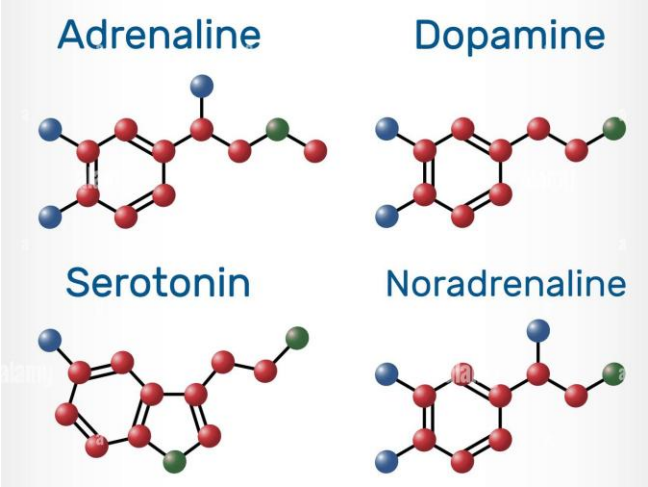

Varianter av fysikalisme

- Reduktiv funksjonalisme
  - Bevissthet er funksjoner utført/implementert (eller realisert) av fysiske mekanismer
  - Og bare det – kan reduseres til det
- Hva er en funksjon?
  - En egenskap definert av sin input og output eller årsaker og virkninger
    - Klokke = noe som viser tiden
    - Penger = noe som kan representere verdi og byttes
  - Substrat-uavhengige – kan utføres av ulike mekanismer/ting/prosesser
    - Klokker kan være mekaniske, kvarts, eller elektroniske
    - Penger kan være laget av metall, papir, «bits» (digitale)

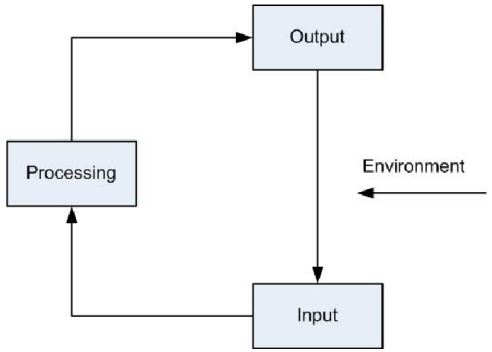

Reduktiv funksjonalisme

- Bevisthetens funksjon
  - Å kunne registrere, rapportere og respondere rasjonelt på indre tilstander (veldig forenklet)
  - Hos mennesker (og dyr) utføres denne funksjonen av biologisk materiale
  - Hvis den samme funksjonen utføres av ikke-biologisk/syntetisk materiale vil vi også ha bevissthet
- Reduktiv funksjonalisme
  - Fenomenal bevissthet er bare funksjonell bevissthet – eller funksjoner vi forbinder med det
  - Bevissthet er substrat-uavhengig
    - Bevisste systemer kan være laget av et hvilket som helst stoff/materiale – så lenge det kan utføre relevante funksjoner

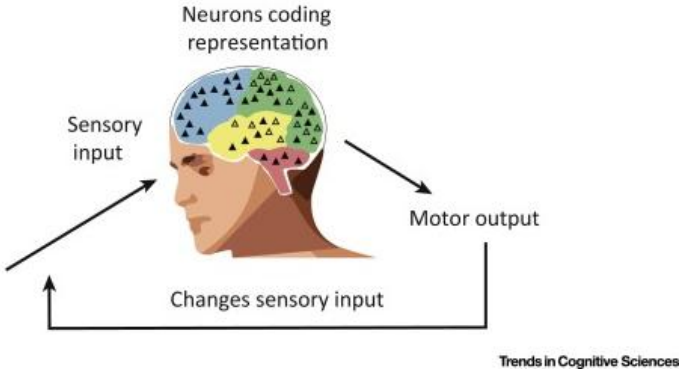

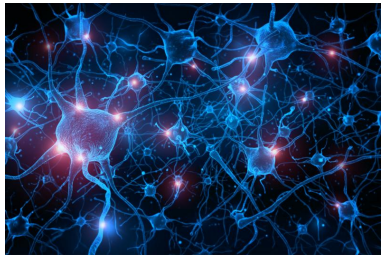

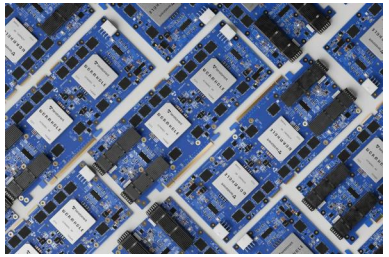

Ikke-reduktiv funksjonalisme

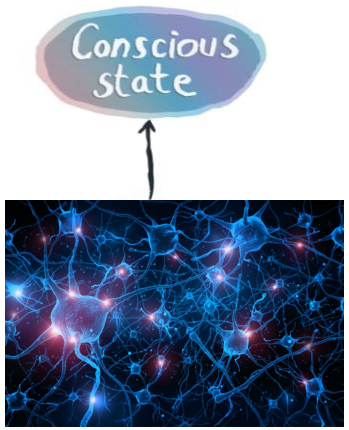

- Dualisme
  - «Biologisk» dualisme
    - Bevissthet forårsakes av biologiske/nevrale konfigurasjoner
  - Ikke-reduktiv funksjonalisme (Chalmers)
    - Bevissthet forårsakes av at visse funksjoner utføres (uavhengig av substrat/mekanisme)
      - Fenomenal bevissthet forårsakes av funksjonell bevissthet – eller nærliggende funksjoner
      - Men er noe mer – kan ikke reduseres til det
- Panpsykisme
  - «Biologisk» panpsykisme
    - Kompleks bevissthet oppstår fra enkel bevissthet ved visse biologiske/nevrale konfigurasjoner
  - Funksjonalistisk panpsykisme
    - Kompleks bevissthet oppstår når visse funksjoner utføres (uavhengig av substrat/mekanisme)

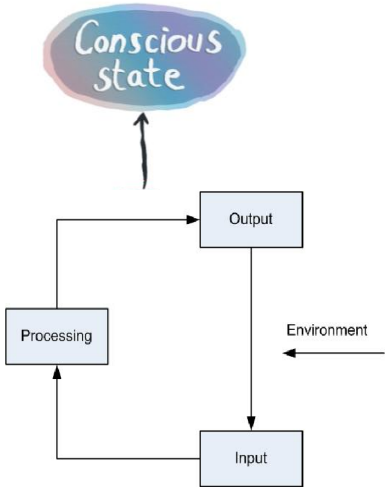

To akser

	Fysikalisme	**Ikke-fysikalisme**
Ikke-funksjonalisme	Identitetsteori/ biologisk naturalisme	«Biologisk» dualisme «Biologisk» panpsykisme
Funksjonalisme	Reduktiv funksjonalisme	Ikke-reduktiv funksjonalisme

- Hvilke ruter tillater KI-bevissthet?

To akser

- Funksjonalisme er det viktige – ikke fysikalisme!
- Hvorfor?
  - KI replikerer (delvis) våre funksjoner – men har et helt annet materiale
  - Kun hvis funksjoner er det som teller for bevissthet, har vi grunn til å tro at KI har det

Oppsummering dag 1

- KI gir opphav til en rekke filosofiske spørsmål
  - Spørsmål som ikke kan besvares ved hjelp av etablerte metoder
  - Om bevissthet/tenkning/språk, etikk, og samfunnsutvikling
- Har KI bevissthet?
  - Fenomenal bevissthet:
    - Subjektiv opplevelse, at det føles/oppleves som noe
  - Funksjonell bevissthet:
    - Å utføre funksjoner som å registrere/behandle/reagere på informasjon
- Problemet om andre sinn
  - Hvordan vet vi at andre har (fenomenal) bevissthet?
    - Fenomenal bevissthet er privat – kan ikke direkte observeres hos andre enn en selv
  - Løsning for mennesker: fysisk likhet → mental likhet
  - Men KI er bare delvis like oss – lignende funksjoner, ulikt stoff/mekanismer

Oppsummering dag 1

- Vitenskapens begrensninger
  - *The hard problem*:
    - Vitenskap kan finne korrelasjoner mellom hjerne og bevissthet – ikke forklare hvorfor de holder
  - Bekreftelsesproblemet
    - Disse korrelasjonene er vanskelige å bekrefte eksperimentelt
    - Siden bevissthet er umulig å observere direkte – og hjernens indre vanskelig å observere
  - Generaliseringsproblemet
    - Korrelasjoner hos mennesker kan ikke generaliseres til KI
    - Holder det med et funksjonelt, men ikke materielt, tilsvarende korrelat? Hvor tilsvarende?
- Kan filosofien hjelpe?
  - Skiller mellom fysikalisme og ikke-fysikalisme + funksjonalisme og ikke-funksjonalisme
  - Gitt funksjonalisme kan KI få bevissthet – i prinsippet
- Neste gang:
  - Argumenter for og mot funksjonalisme
  - Har KI nok funksjonell likhet eller riktige funksjoner?
  - Andre filosofiske tester for bevissthet (Turing-testen, ACT-testen, m.fl.)