

Etikk 1: Selvkjørende biler, autonome våpen og ansvarsgap

Selvkjørende biler og kollisjons-scenarier

- Selvkjørende biler kan være langt sikrere enn konvensjonelle biler – men ulykker vil finne sted.
- De kjører blant uforutsigbare fotgjengere, syklister og menneskelige sjåfører, under varierende forhold
- De må programmeres *på forhånd* for hvordan de skal håndtere kollisjons-scenarier
 - Hva slags etisk rammeverk ønsker vi at selvkjørende biler skal programmeres etter, når ulykker finner sted?
 - Skal bilen alltid prioritere eierens sikkerhet?
 - Skal den forsøke å minimere totalt antall skadde?
 - Skal alle biler ha de samme etiske innstillingene – eller skal eieren velge?


Autonome biler i dag: Bruk og ulykker

- Bruksområder i dag:
 - **Waymo:** Robotaxi-tjenester i Phoenix, Atlanta, Miami San Francisco og Los Angeles og snart mange andre steder i USA (uten sjåfør)
 - **Tesla:** Autopilot og Full Self-Driving (krever menneskelig oppsyn)
 - **Cruise (GM):** Robotaxi i San Francisco – suspendert etter alvorlig ulykke i 2023
- Ulykker:
 - Waymo rapporter selv at de har 90% færre alvorlige ulykker sammenlignet med menneskelige sjåførere.
 - <https://waymo.com/safety/impact>

Driverless taxi usage in California has grown eightfold in just one year

Our World
in Data

Monthly passenger miles traveled in California's paid driverless taxis, summing the miles traveled by individual passengers across all trips.




Data source: California Public Utilities Commission (2025)


OurWorldinData.org/artificial-intelligence

CC BY

Generell problemstilling

- Selvkjørende biler har potensiale til å være langt tryggere enn biler med menneskelige sjåfører
- Men ulykker vil finne sted
- Hva slags etisk rammeverk ønsker vi at selvkjørende biler skal programmeres etter, når ulykker finner sted?
-





- <https://www.moralmachine.net/>

Trolleyproblemet og dets begrensninger

- Trolleyproblemet brukes ofte som analogi for etikken rundt selvkjørende biler – Nyholm er skeptisk til dette:
- abstraherer bort all kompleksitet. Selvkjørende biler møter komplekse og uoversiktlige situasjoner i den virkelige verden
- setter ansvarsspørsmål til side. Men ansvar er et av de mest sentrale spørsmålene i trafikketikken
- forutsetter full visshet om utfallet. Programmering av biler skjer under *usikkerhet* – det handler om risikostyring, ikke determinisme

Etiske teorier og algoritmer for kollisjon

- Ulike etiske teorier kan potensielt gi ulike svar på hvordan bilen bør programmeres i krasj-scenarier:
- **Utilitarisme:** Minimer totalt antall skadde og drept. Bilen bør alltid velge det utfallet som gir minst samlet skade
 - Men utilitarisme vil ikke se bilens algoritmer i isolasjon
- **Kantianisme:** Noen handlinger er moralsk gale uavhengig av konsekvensene. Man bør ikke bruke noen som et middel – selv om det ville redde flere.
- **Dydsetikk:** Hva ville en dydsfull sjåfør gjort? Bilen bør etterligne menneskelig moralsk skjønn
- **Kontraktualisme:** Regler bør kunne forsvares overfor alle berørte parter. Hva kan alle rimeligvis godta?

Felles eller individuelle etikkinnstillinger?

- Bør alle selvkjørende biler ha de samme etiske innstillingene – eller bør eieren velge?
- **For felles innstillinger:** Etikk bør ikke være et markedsprodukt. Personlig preferanse kan ikke rettferdiggjøre at andres liv settes i fare
- **For individuelle innstillinger:** Selvbestemmelse og personlig frihet er viktige verdier. Forbrukere kan ha legitime forskjellige prioriteringer
- **Empirisk forskning (Bonneton m.fl.):** Folk ønsker at biler skal minimere totalt antall drepte – men vil ikke kjøpe en bil som kan ofre dem selv

Ideell vs. Ikke-ideell teori

- Ideell teori:
 - Måten selvkjørende biler ideelt sett burde programmeres
- Ikke-ideell teori:
 - Måten selvkjørende biler burde programmeres, gitt at folk ikke nødvendigvis ville bruke biler som er programmert etter ideell teori

Ansvar og ansvarsmangler

- Hvem er ansvarlig når en selvkjørende bil forårsaker en ulykke?
- **Juridisk:** Mulige ansvarssubjekter er produsent, programvareingeniør, eier og passasjer
- **Ansvarsgapet:** Bilen handler, men bilen kan ikke holdes moralsk ansvarlig
- **Straffegapet (Danaher):** Automatiserte systemer kan ikke straffes eller klandres som mennesker
- **Nyholms løsning:** Selvkjørende bilers handlinger bør forstås som del av et *menneske-robot-samarbeid*. Mennesker er overordnede aktører og beholder ansvaret

Nye etiske forpliktelser og blandet trafikk

- Dersom selvkjørende biler faktisk er sikrere enn vanlige biler, oppstår nye etiske spørsmål:
- **Plikt til det tryggere alternativet?** Nyholm og Smids argumenterer for at folk kan ha en plikt til å enten gå over til selvkjørende biler, eller akseptere ekstra sikkerhetstiltak ved konvensjonell kjøring
- **Blandet trafikk:** En periode der selvkjørende og menneskestyrte biler kjører side om side skaper etiske koordineringsutfordringer
- To problematiske alternativer:
 - Tilpasse selvkjørende biler til menneskelig kjøreatferd – gir avkall på sikkerhetspotensial
 - Tvinge mennesker til å kjøre mer som roboter – begrenser personlig frihet og selvbestemmelse

Etikk i rutinekjøring – ikke bare i krisesituasjoner

- Etikken ved selvkjørende biler handler ikke bare om dramatiske krasj-scenarier
- Også ordinær kjøring innebærer etisk relevante valg:
 - Avstand til forankjørende, bremsestrategi, lateral posisjonering i kjørefeltet
 - I hvilken grad bilen kan overtre trafikkregler
- Disse valgene innebærer å fordele risiko mellom ulike trafikanter – og *risikostyring er grunnleggende sett et etisk anliggende*
- Programmering av selvkjørende biler er dermed en form for **kodifisert etikk** – uavhengig av om det dreier seg om krasj-situasjoner eller hverdagskjøring

Tar produsentene hensyn til filosofiske dilemmaer?

- Hva sier produsentene:
 - Waymo og Tesla prioriterer kollisjonsvarsling og automatisk nødbremsing – ikke eksplisitte «trolley-valg»
 - Waymo bruker anonyme kategorier (TYPE_PEDESTRIAN) – ingen differensiering etter alder, kjønn eller antall
- Hva filosofer mener mangler:
 - Bilene er ikke programmert til eksplisitt å avveie liv mot hverandre – ansvarsgapet er ikke løst
 - Mangel på åpenhet om de etiske prinsippene bak algoritmene
 - Gap mellom teori og praksis: Filosofisk litteratur diskuterer dilemmaer industrien i stor grad unngår å ta stilling til

Autonome våpen

- “UN Secretary-General António Guterres has once again called for a global ban on lethal autonomous weapon systems – machines capable of taking human lives without human oversight – describing them as “politically unacceptable” and “morally repugnant.” UN news May 14th, 2025.
- Autonomous weapons systems present numerous risks to humanity, most of which infringe on fundamental obligations and principles of international human rights law. (Human Rights Watch, 2025)
- “og ta nødvendige initiativ for å regulere utviklingen av selvstyrte våpensystemer” (Hurdalsplattformen, 2021)



Tekniske, praktiske og prinsipielle spørsmål

- Utviklingen av ny våpenteknologi (og mye annen teknologi) reiser typisk to typer etiske spørsmål:
- **Tekniske/praktiske:**
 - kan våpenet misbrukes,
 - Vil bruken av våpenet gjøre andre problematiske ting mer sannsynlig
- **Prinsipielle spørsmål:**
 - Er bruken av våpenet problematisk selv om det brukes på riktig måte og ikke sannsynliggjør andre negative konsekvenser
 - Den første typen spørsmål er ofte viktigere, men den andre typen spørsmål er typisk mer filosofisk interessant.

Tekniske utfordringer

- Kan autonome våpen overholde:
- **Distinksjonsprinsippet:** Kun stridende er legitime mål
- **Proporsjonalitetsprinsippet:** Det må være *et rimelig forhold* mellom forventet militær effekt og sivile tap

Nivåer av autonomi

- *Semi-autonome våpen* (human-in-the-loop), der avgjørelsen om å avfyre våpenet tas av et menneske. Eks: Bevæpnede droner, varmesøkende missiler.
- *Autonome våpen under oppsyn* (human- on- the- loop), der våpenet selv kan velge ut og angripe målet, samtidig som hele prosessen overvåkes og kan avbrytes av et menneske. Eks: antimissilsystemer som Israels Iron Dome.
- *Fullt autonome våpen* (human- out- of- the- loop) som selv kan velge ut og angripe mål uten menneskelig overoppsyn. Finnes ikke i dag.

Utfordringer som autonome våpen har til felles med droner

- Fare for misbruk
- Mulighet for omprogrammering
- Lavere terskel for krig?
- Demokratisk underskudd?
 - Droner setter ikke egne soldater i umiddelbar fare.
 - «If war becomes unreal to the citizens of modern democracies, will they care enough to control and contain violence in its name» (Michael Ignatieff, 2000)
 - Når krigføring ikke innebærer tap av egne soldater, hva skjer med den offentlige debatten?

Destruktiv teknologi

- **Drone swarms.** Agile winged drones can already be built to the size of a bumblebee. A radio receiver, control circuitry, battery, actuators, and a payload of explosives, poison, or pathogens could fit into a volume the size of a large beetle.
- **A technology explosion** could make it possible to build vast drone armies with truly enormous destructive potential. One deadly, autonomous, insect-sized drone for each person on Earth could fit inside a single large aircraft hangar
- So they could potentially be built quickly and secretively. It is currently much cheaper to build and operate a swarm of drones than to protect against them, so drones may favour offence over defence in warfare, as they become more widely used.



Argumentet basert på menneskelig verdighet

Prinsipielle utfordringer

- FNs spesialrapportør:
- “UN Secretary-General António Guterres has once again called for a global ban on lethal autonomous weapon systems – machines capable of taking human lives without human oversight – describing them as “politically unacceptable” and “morally repugnant.” UN news May 14th, 2025.
- even if it “can be proven that on average and in the aggregate they will save lives, the question has to be asked whether it is not *inherently wrong* to let autonomous machines decide who and when to kill. . . . The question here is whether the deployment of LARs against anyone, including enemy fighters, is *in principle* acceptable, because it entails non-human entities making the determination to use lethal force.”
- UN Doc A/HRC/23/47 (9 April 2013), para. 92-93.]



- *Human Dignity*: The principle of human dignity underlies all human rights, including the right to life, and establishes that people have inherent worth that is both universal and inviolable. Autonomous weapons systems would contravene that foundational principle due to their process of making life-and-death determinations. These machines would kill without the uniquely human capacity to understand or respect the true value of a human life because they are not living beings. Furthermore, they would instrumentalize and dehumanize their targets by relying on algorithms that reduce people to data points.
- (Human Rights Watch: *A Hazard to Humanity: Autonomous Weapons Systems and Digital Decision-Making*, 28 April 2025)

Ansvarsoppsmuldring

- Hvem skal holdes ansvarlig når uskyldig blir drept?
 - Produsenten? Politikerene? Offiseren? Våpensystemet?
 - Er det *respektløst* dersom ingen kan holdes ansvarlig?

Ansvarsoppsmuldring: Sparrows argument

1. It is a fundamental condition of fighting a just war that someone may be held morally responsible for the deaths of enemies killed in the course of it. In particular, someone must be held responsible for civilian deaths.
2. Neither the programmer of AWS nor its commanding officer could justly be held morally responsible for the deaths of enemy combatants caused by AWS.
3. We could not justly hold AWS itself morally responsible for its actions, including its actions that cause the deaths of enemy combatants.⁴
4. There are no other plausible candidates for whom we might hold responsible for the deaths of enemy combatants caused by AWS.
5. Therefore, there is no one whom we may justly hold responsible for the deaths of enemy combatants caused by AWS.
6. Therefore, it is impermissible to wage war through the use of AWS. To do so would be to treat our enemy like vermin, as though they may be exterminated without moral regard at all.

Sparrows argument

- Premiss 1: Forbindelsen mellom ansvar og respekt
- “If we fail in this we treat our enemy like vermin, as though they may be exterminated without moral regard at all. The least we owe our enemies is allowing that their lives are of sufficient worth that someone should accept responsibility for their deaths.”
- Sparrow 2007:69

Ansvarsoppsmuldring

- Det er respektløst å ikke holde personer *som faktisk er ansvarlige* for drap ansvarlige.
- Men hva hvis ingen er ansvarlige? Sammenlign ulykker.
- Subjektiv vs. objektivt ansvar.
- Samme problem for autonome biler



Fravær av moralsk motivasjon

- Autonome våpen handler ikke etter moralske grunner
- Er dette problematisk?
- Sammenlign:
- Rasistiske soldater: det virker problematisk å benytte seg av soldater som handler etter moralsk forkastelig grunner, selv om de følger krigens folkerett
- Sosiopatiske soldater: det virker problematisk å benytte seg av soldater som kun er motivert av å følge regler, selv om de følger krigens folkerett
 - Ville det være galt å benytte seg av en sosiopatisk soldat som følger regler? I såfall, hvorfor?

Purves, Jenkins og Strawser

- Det finnes en plausibel moralsk innvending mot å bruke en sosiopatisk soldat som oppfyller sine militære forpliktelser, men som ikke handler etter moralske grunner
- Det er en berettiget presedens innen rettferdig krig – tradisjonen for at det å ha rett intensjon er en betingelse for å gå til krig
- Rettferdig krig-teoretikere har også vektlagt betydningen av intensjonene individuelle soldater har når de handler i en krig
- De epistemiske problemene knyttet til rett intensjon for soldater gjelder ikke for autonome våpen

Fravær av moralsk motivasjon

- Verdien av rett intensjon:
- Alternativ 1: Fravær av rett intensjon gjør *handlingen umoralsk*.
- Ser ikke ut til å stemme som et generelt prinsipp

Alternativ 2: Fravær av rett intensjon gjør at handlingen
mangler moralsk verdi.

- Men hvordan veie manglende moralsk verdi opp mot flere sivile tap?

Purves, Jenkins og Strawser

- 1. Hvis en handling som involverer liv og død mangler den rette intensjonen, er handlingen moralsk utillatelig.
- 2. Autonome våpen kan ikke handle med rett intensjon.
- 3. Alle handlinger som involverer liv og død og utføres av autonome våpen, er moralsk utillatelige.

Doktrinen om dobbel effekt


- Hvis målet for din handling er moralsk ønskelig, så kan du velge dette handlingsalternativet selv om du forutser at handlingen din vil medføre skade. Men du kan aldri intendere å påføre andre skade.
 - Handlingen er *nødvendig* for å oppnå målet
 - Det må være *proporsjonalitet* mellom målet for handlingen din og den forutsette
 - De som skades må ikke brukes som et middel

Doktrinen om dobbel effekt

- **Tactical Bomber:** A bomber drops a bomb on a munition factory in order to secure his side a significant military advantage. The bomber knows that fifty non-combatants in a nearby children's hospital will be killed as a side-effect of the blast.
- **Terror Bomber:** A bomber drops a bomb on a children's hospital in order to kill fifty non-combatants. This will terrorize the local munition workers into quitting

Doktrinen om dobbel effekt

- Men det er kontroversielt hvorvidt en persons intensjon kan avgjøre hvorvidt en handling er moralsk riktig eller gal.
- Det er også uklart om fraværet av en intensjon kan gjøre en handling gal.
 - Søvnjengereksempel



- “AWS are morally problematic because they are incapable of performing morally worthy actions.” Purves, Jenkins og Strawser,
- Man kan argumentere for at moralsk forståelse og prisverdighed har moralsk verdi i seg selv.

- Argumentet er ikke kun ment å gjelde scenarioer der autonome våpen er like gode som mennesker til å etterfølge in bello-prinsippene, men også scenarioer hvor autonome våpen er noe bedre enn mennesker.
- Men kan verdien av moralsk forståelse eller prisverdighet veie opp for tap av uskyldige liv?

- Sammenlign David Enoch om medlidenhet (som også er verdifullt i seg selv):
- Someone willing to tolerate greater suffering – even by a small margin, and even just the greater probability of greater suffering – merely to work on his (or anyone else's) compassion, that is, independently of the supposed instrumental payoffs of having more compassionate people around, is acting wrongly, and most clearly uncompassionately
- Det samme poenget kan gjøres for moralsk forståelse eller prisverdighet