Kunstig intelligens og bevissthet

Kunstig intelligens og filosofi (FIL1010), INN

Hedda Hassel Mørch

06.02.2026

Forrige gang

- Har KI bevissthet?
  - Interessant i seg selv
  - Viktig for etiske og andre videre spørsmål (**mer senere** i emnet)
- Må skille mellom:
  - Fenomenal bevissthet: subjektiv opplevelse, at det føles/oppleves som noe
  - Funksjonell bevissthet (eller funksjoner forbundet med bevissthet)
    - Å registrere/behandle/reagere på informasjon om seg selv eller miljøet (f. eks.)

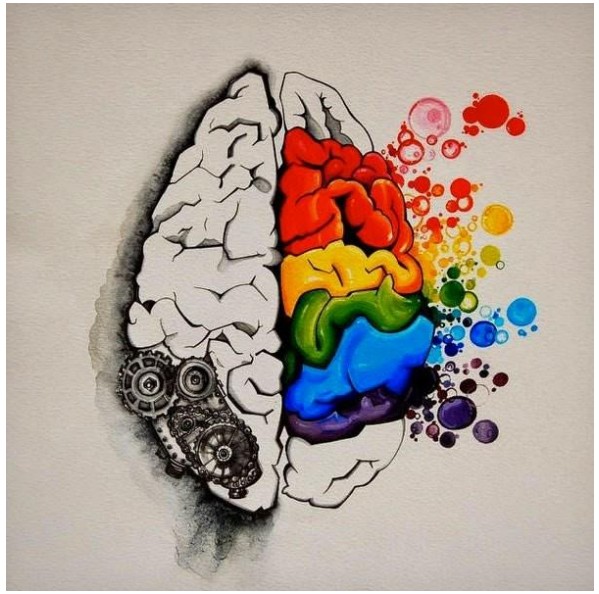

Forrige gang

- Funksjonalisme
  - Fenomenal bevissthet er korrelert med funksjoner – substrat-uavhengig
  - Ikke-funksjonalisme: bevissthet er korrelert med nevrale/biologiske prosesser – substrat-avhengig
- Funksjonalisme og fysikalisme
  - Funksjonalisme + fysikalisme = reduktiv funksjonalisme
    - Bevissthet er bare funksjoner – utført av fysiske mekanismer
    - Fenomenal bevissthet er bare funksjonell bevissthet
  - Funksjonalisme + ikke-fysikalisme = ikke-reduktiv funksjonalisme
    - Ikke-reduktiv funksjonalisme = bevissthet produseres av (men er noe mer enn) funksjoner (dualisme
      - Eller mental kombinasjon utløses av funksjonell sammensetning (panpsykisme)
  - Ikke-funksjonalisme + fysikalisme = identitetsteori/biologisk naturalisme

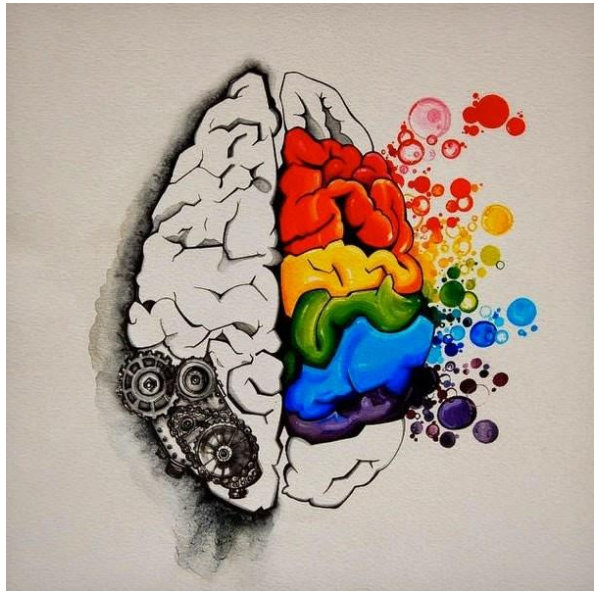

I dag

- Funksjonalisme alene betyr ikke at KI har bevissthet
  - KI må utføre riktige funksjoner
- Hvilke funksjoner er de riktige? Ulike syn:
  - Fra et generelt filosofisk/teoretisk synspunkt
  - Fra vitenskapelige teorier om bevissthet
- Andre foreslåtte tester for KI-bevissthet
  - Turing-testen
  - ACT-testen

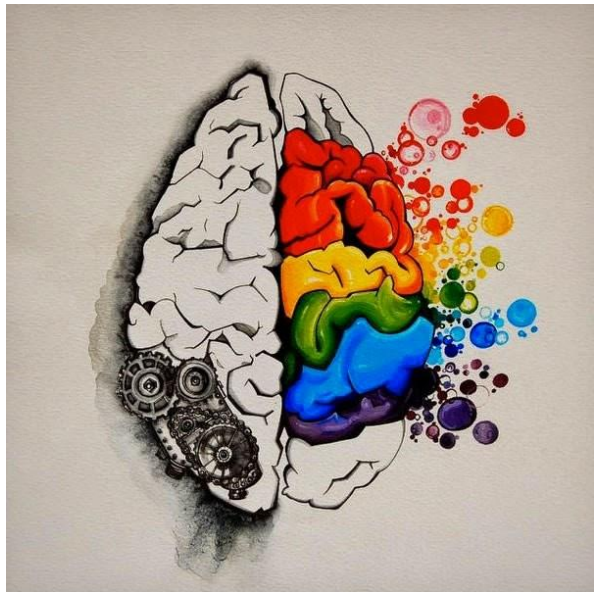

Men aller først

- Ulike typer funksjonalisme
- Argumenter for og mot funksjonalisme

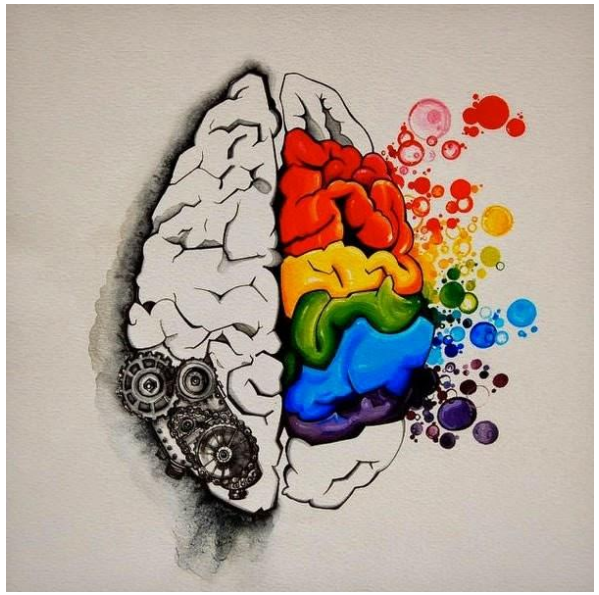

Fra behaviorisme til funksjonalisme

- Behaviorisme
  - Mentale tilstander er adferdsdisposisjoner – eller funksjoner fra stimulus til adferd
    - Smerte er å være disponert til å si «au», gråte eller skrike, prøve å flykte, etc.
    - Sult er å finne/oppsøke mat hvis man ikke har det, spise den hvis man har det
  - Bevissthet generelt
    - Å være i en eller flere av tilstandene definert som mental
    - Å kunne snakke/rapportere, å handle på en måte som er tilpasset miljøet, å kunne lære, etc.
  - Å vise adferd Y gitt stimulus X – for mange ulike X-er og Y-er
    - Der Y er adferd og X er stimulus
- Problem:
  - Mentaltilstander vises ikke alltid som adferd
    - Man kan ha smerte uten å vise det, være sulten uten å spise, osv.
  - Samme adferd kan vises med og uten bevissthet
    - Søvngjengeri, etc.

Psykologisk funksjonalisme

- Mentaltilstander er funksjoner mellom ikke bare stimulus og adferd – men også andre mentaltilstander
  - Smerte er å være disponert til å si «au» hvis man tror noen vil gi sympati, og man ikke tror at noen vil høre det og synes du er pysete, +++
  - Å tro noe (en oppfatning) er noe som sammen med et ønske leder til adferd
    - Hvis man ønsker X (f. eks penger) og tror Y leder til X (f. eks. å gå på jobb) så vil man gjøre X (gå på jobb)
- Bevissthet generelt
  - Å kunne registrere informasjon om miljøet og egne indre tilstander, integrere informasjonen med tidligere lagret informasjon, og generere handling basert på samlet informasjon

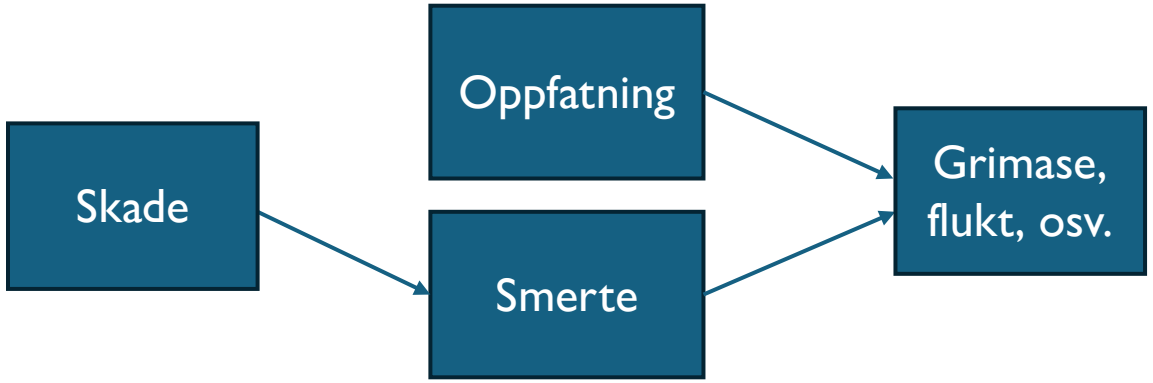

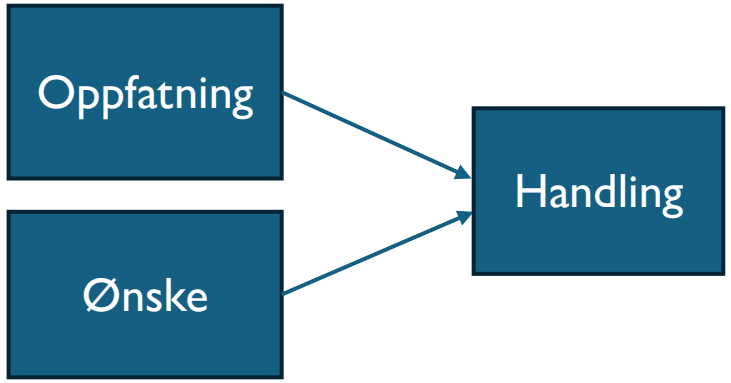

Psykologisk funksjonalisme

- Fordeler over behaviorisme
  - Kan forklare hvorfor mentaltilstander ikke alltid vises i adferd
  - Kan forklare hvorfor (noe) adferd kan utføres bevisst og ubevisst
    - Bevissthet er ikke bare adferd (eller disposisjon til det), men adferd som produseres på <u>en viss måte</u>
  - → Tar høyde for at bevissthet er <u>privat</u> og <u>indre</u>

Komputasjonell funksjonalisme

- Bevissthet er å implementere en type programvare (*software*) eller algoritme
- En komputasjonell funksjon
  - Input og output må være (eller kunne tolkes som å være) informasjon
    - I form av binære strenger (1011101, 0010110, etc) eller andre formelle symboler
- For oss
  - Bevissthet er «software» som kjører på hjernen som «hardware»
- Men:
  - Samme «software» kan i prinsippet kjøre på hvilken som helst hardware

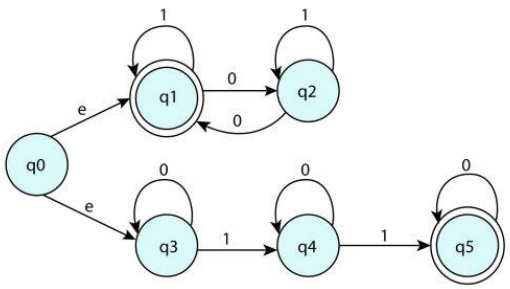

Komputasjonell funksjonalisme

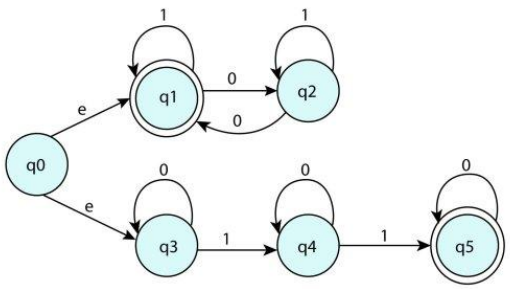

- Fordeler over psykologisk funksjonalisme
  - Gir en dypere forklaring på psykologiske funksjoner
    - Hvordan utføres funksjoner som å følge logiske regler i tenkning, forstå språk, osv?
    - Ved å kjøre et dataprogram/algoritme
- De fleste funksjoner kan forstås som komputasjonelle funksjoner
  - Smerte = å disponere til unngåelse gitt visse oppfatninger
    - → å være i en tilstand der viss input (som er kode for oppfatninger) leder til visse (som er kode for instruksjoner til unngåelse)
  - Bevissthet generelt å kjøre et visst komplekst program/algoritme
    - Som skriver ut instruksjoner for adferd/andre responser gitt ulike typer sanseinntrykk/annen stimulus
    - En stimulus/respons-funksjon – som behaviorisme – men må medieres av riktig algoritme
- Psykologisk funksjonalisme kan «oversettes» til komputasjonelle

Argument <u>for</u> funksjonalisme

- Multippel realisering
  - Realisere = utgjøre, utføre, være basis for noe
  - Multippel realisering = når noe kan realiseres av ulike ting
    - En statue kan realiseres av bronse, marmor, gips, leire, mm

Argument <u>for</u> funksjonalisme

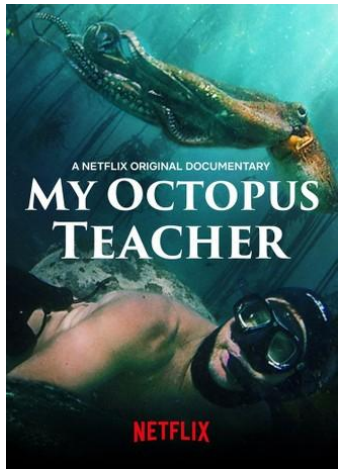

- Argumentet fra multippel realisering
  1. Bevissthet er multippelt realiserbart
     - Bevissthet kan være tilstede i veldig ulike organismer/systemer
       - <u>Blekkspruter</u> virker bevisste – men har en helt annen hjerne
       - Hvis <u>romvesner</u> kom til jorden og viste alle tegn på bevissthet ville vi tenkt de hadde det – selv om de hadde helt annet biologi
  2. Bevissthet er multippelt realiserbart bare <u>gitt funksjonalisme</u>
     - Spesielt tydelig for <u>komputasjonell funksjonalisme</u>
       - Irrelevant for programvaren hva maskinvaren er laget av (så lenge den klarer å kjøre programmet)

---

  3. **Funksjonalisme er sant**
- <u>Med andre ord:</u> ikke-funksjonalisme (biologisk naturalisme, osv.) er for <u>sjåvinistisk</u>
  - Favoriserer oss selv uten god grunn

Argumenter mot funksjonalisme

- Funksjonalisme er for liberalt
  - Funksjoner kan være ekstremt multippelt realiserbare
- Komputasjonell funksjonalisme
  - Mange typer datamaskiner finnes
    - Mekaniske, radiorør, elektroniske, kvantebaserte
    - DNA, kjemisk, optisk +++ (teoretiske design)
  - Alle kan i prinsippet kjøre alle programmer – inkludert hjernens
    - Ikke nødvendigvis raskt, praktisk og effektivt, men likevel
  - Gitt funksjonalisme, så vil de da ha bevissthet!
- «Kina-hjernen» (Ned Block)
  - Se for deg en befolkning på en milliard mennesker (derfor Kina)
  - Hvert menneske simulerer ett nevron i menneskehjernen
  - Kommuniserer (via radiosignaler) så alt eksakt replikerer hjernens nevrale struktur og aktivitet
  - Gitt funksjonalisme, så vil befolkningen da ha bevissthet!
    - Som helhet, ikke de enkelte medlemmene

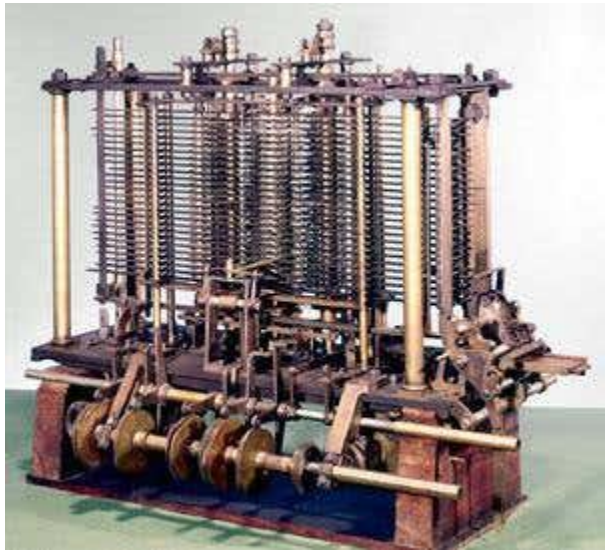

Kina-hjernen

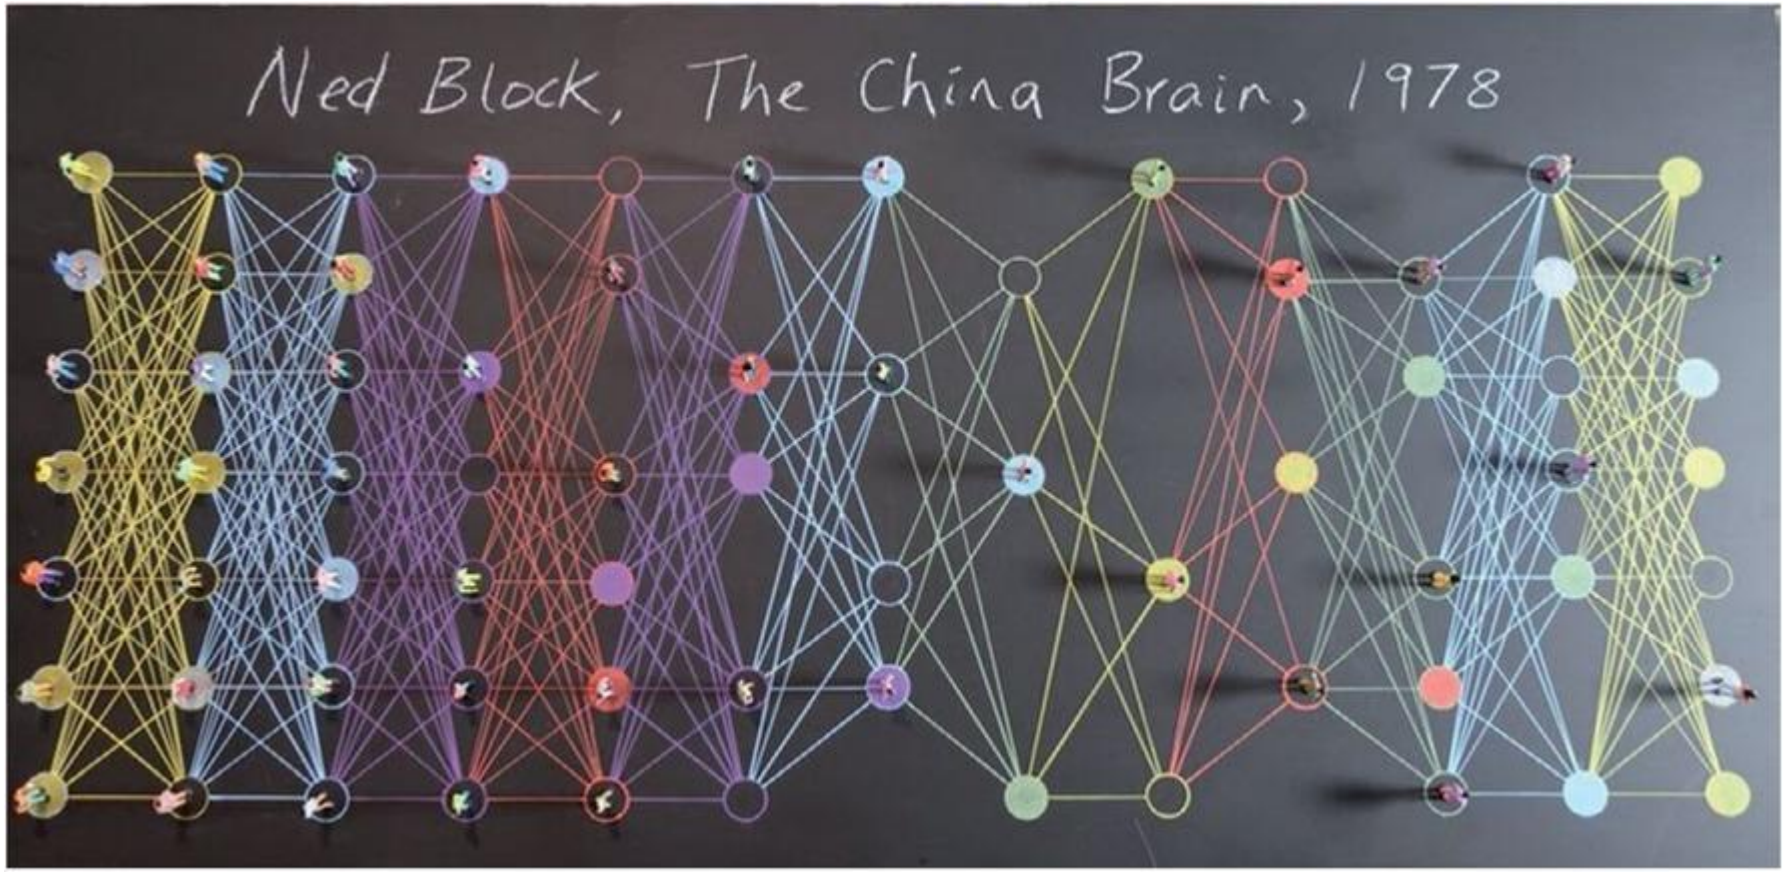

Diskusjon

- Stemmer funksjonalisme?
  - Reduktiv eller ikke-reduktiv
- Stemmer komputasjonell funksjonalisme?
- Hvorfor/hvorfor ikke?

Funksjonalisme og KI-bevissthet

- Funksjonalisme medfører at kunstig bevissthet er mulig i prinsippet
  - Spesielt komputasjonell funksjonalisme
    - Dagens datamaskiner er universelle – kan kjøre alle mulige programmer
    - Hvis bevissthet er et program, så kan et kunstig system ha (eller gi grunnlag) for det
  - Ikke-komputasjonelle funksjoner kan ikke automatisk utføres av KI
    - Må vurderes for hver funksjon
- Men ikke at det er virkelig nå eller i overskuelig fremtid
- Kommer an på:
  - Hvilke funksjoner som er nødvendige/tilstrekkelige for bevissthet
    - Hvilken type program – eller annen funksjon?
  - Hvilke funksjoner vi finner hos KI – nå eller i overskuelig fremtid
- Vi følger Chalmers: «Could a large language model be conscious?»
  - Handler om språkmodeller (LLM-er) – den mest generelle kunstige intelligensen vi har nå
  - LLM = large language model (ChatGPT og lignende)

Hvilke funksjoner er nødvendige?

- Alle funksjoner mennesker har?
  - Dagens KI deler noen, men langt fra alle, våre funksjoner
    - Generell fysisk navigering/manipulering, kontinuerlig læring, læring fra begrenset data, selvstendig vitenskapelig aktivitet ++
  - Har derfor ikke bevissthet?
  - Men KGI deler alle mennesker kognitive funksjoner – kan kvalifisere
    - KGI = kunstig generell intelligens
- Svar
  - Dyr mangler mange menneskelige funksjoner, men vi tror fortsatt (noen) dyr har bevissthet.
  - Derfor kan ikke alle våre funksjoner – eller vår grad av dem – være nødvendig for bevissthet.

Generell intelligens

- Generell intelligens på <u>menneskenivå</u> er kanskje ikke <u>nødvendig</u>
  - Jf. dyr
- Men er det <u>tilstrekkelig</u>?
  - Vil KGI nødvendigvis få bevissthet?
- Kan <u>grad</u> av generell intelligens tilsvare grad av bevissthet?
  - Dagens KI har allerede <u>en grad av</u> generell intelligens
    - Ikke like høy – på alle områder – som mennesker
  - Har dagens KI derfor en <u>grad</u> av bevissthet?

Finkornet vs. grovkornet funksjonalisme

- Grovkornet funksjonalisme
  - Bevissthet er en enkel input/output-funksjon
    - «Hvis x så y» – for ulike x-er og y-er
    - Samme hvordan x leder til y
  - Behaviorisme er en veldig grovkornet funksjonalisme
    - Med adferd som output
  - → KGI har identisk (kognitiv) input/output-struktur som et menneske – har derfor bevissthet – i følge (veldig) grovkornet funksjonalisme

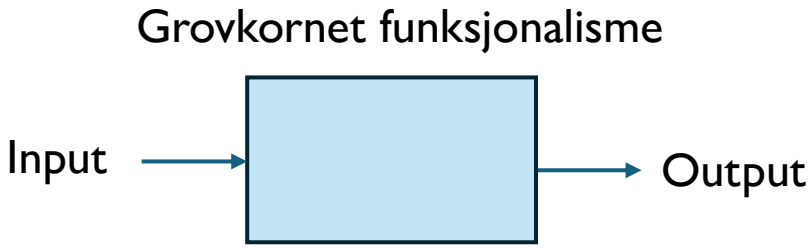

Finkornet vs. grovkornet funktionalisme

- Finkornet funksjonalisme
  - Bevissthet er en kjede og/eller et hierarki av input/output-funksjoner
  - Adferd må produseres på en viss måte
    - Via visse underfunksjoner
    - Eller via en bestemt algoritme
  - Eller annen output
    - Adferd trenger ikke være koblet til funksjonen – bevissthet kan være en funksjon mellom indre tilstander
    - Hos oss er bevissthet vanligvis koblet til adferd
    - Men må ikke alltid være det – kommer an på hvilken versjon av

Finkornet funksjonalisme

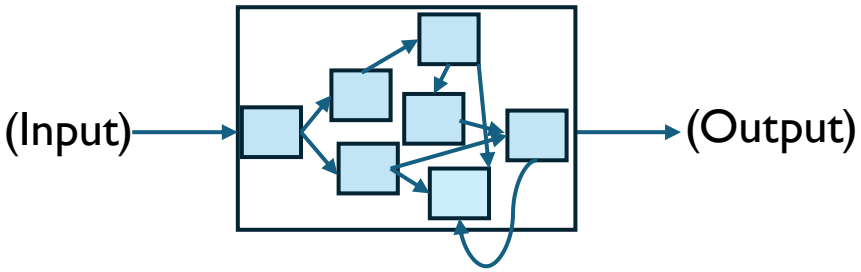

Finkornet vs. grovkornet funksjonalisme

- Hvor finkornet?
  - Må en KI replikere funksjonell struktur mellom:
    - Områder?
    - Nevrongrupper?
    - Enkelte nevroner?
    - Elementer inni nevronene?
- KI replikerer våre grovkornede funksjoner
  - Kan snakke, resonnere, etc.
- Men kanskje ikke de finkornede
  - Vi vet ikke om de bruker samme «algoritme»
  - Eller har andre relevant likheter på lavere funksjonelt nivå

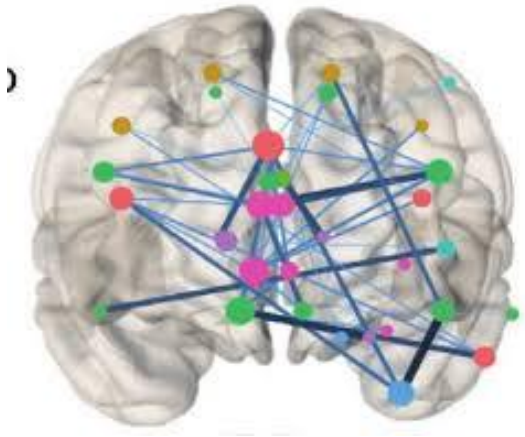

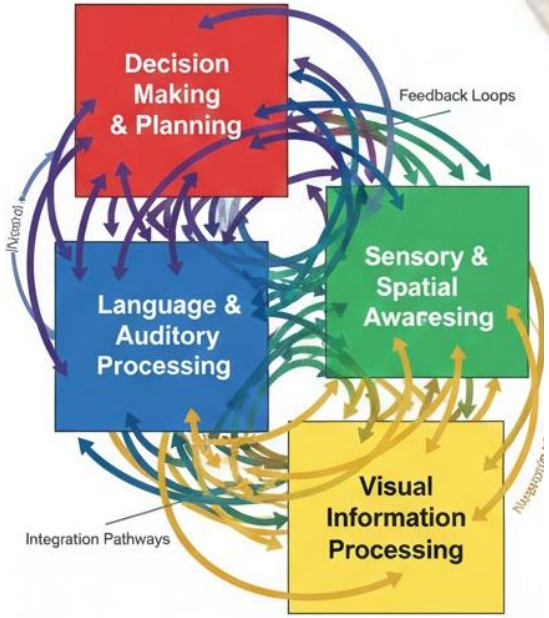

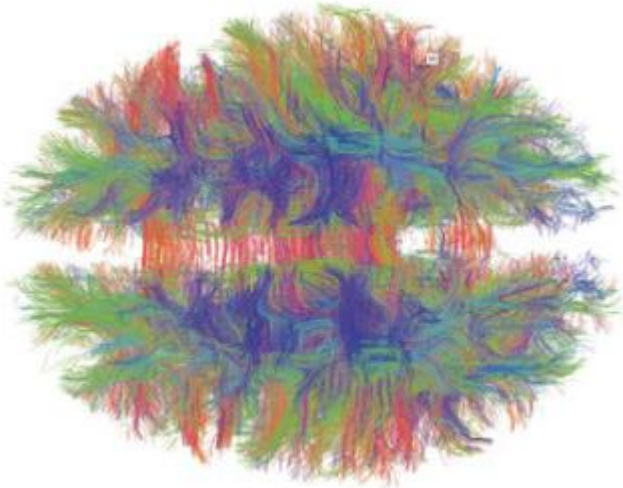

Hvilke funskjoner kan være nødvendige/tilstrekkelige for bevissthet?

- Grovkornede funksjoner (Chalmers)
- Funksjoner identifisert av vitenskapelige teorier

Persepsjon (sansing) og kropp

- LLM-er tar input og gir output i form av tekst – vi gjør det via sansing og kroppen
  - Andre typer KI-er har noe nærmere sansing og kropp (f. eks. selvkjørende biler) – men har mye smalere intelligens
- Er det nødvendig?
  - Vår bevissthet kan frakobles sanser og kontroll av kroppen
    - I drømme, ved lammelse, blindhet, osv.
  - Så kanskje ikke!
- Har KI det?
  - Selv LLM-er har en grad av sansing
    - Kan ta bilder og tale som input
  - LLMer (eller KI som integrerer det) kan installeres i roboter

Verdensmodell og selv-modell

- LLM-er har modeller av språket, ikke modeller av verden
  - Produserer tekst ved å forutse det fra annen tekst
  - Andre typer KI (f. eks. selvkjørende biler) har kanskje noe nærmere verdensmodell, men (igjen) mye smalere intelligens
- Mennesker har modeller av verden og oss selv
  - Vi produserer tekst ved å prøve å beskrive verden – og oss selv
    - Hvordan verden er (eller fremstår for/representeres av oss)
    - Hvordan vi vil/ønsker den skal være
    - + ut fra modell av andre mennesker (hvis vi vil påvirke dem på ulike måter)
- Er det nødvendig?
  - Chalmers: ikke åpenbart
- Har KI det?
  - Tekst som LLM-er trener på inneholder mye informasjon om verden
    - Kanskje LLM-er bygger en verdensmodell ut fra tekst og bruker den til å forutse tekst?
    - VI vet at LLM-er forutser tekst – men ikke hvordan!
  - LLM-er kan integreres med andre typer KI som trener på fysisk data (video, feedback til roboter, osv.)

Forent handling (*unified agency)*

- Chalmers: «LLMs often seem to lack stable goals and beliefs of their own over and above the goal of predicting text.»
  - Får nye mål hele tiden avhengig av hva brukeren vil
- Er dette nødvendig?
  - Chalmers: Noen mennesker mangler stabile mål («multippel personlighet» (DID), schizofreni, hukommelsesproblemer)
- Har KI det?
  - «Agentive» modeller er under utvikling
  - Teoretikere bekymret for usamstemt (*misaligned*) KI mener de kan utvikle egne mål i konflikt med våre – mer på **senere forelesning**

Hva sier vitenskapelige teorier om bevissthet?

- Long, Butlin et al. skiller mellom:
- Teorier <u>forenelige</u> med komputasjonell funksjonalisme
  - Global workspace theory
  - Recurrent processing theory
  - Mange flere
  - <u>Åpner</u> for – men garanterer (i utgangspunktet) ikke – KI-bevissthet
- Teorier <u>ikke forenelige</u> med komputasjonell funksjonalisme
  - IIT
  - Biologisk naturalisme
  - Disse utelukker antagelig KI-bevissthet – mer **senere**
- <u>Hvor sterkt</u> åpner de komputasjonelle teoriene for KI-bevissthet?

Long, Butlin, et al.

- Analyserer hver teori
  - «Global workspace»-teorien
    - Bevissthet krever kringkasting av informasjon i et «globalt arbeidsrom»
      - Et sentralt knutepunkt der informasjon fra ulike kilder integreres
      - Ulike sansemodaliteter (hørsel, syn, lukt, balanse, mm), hukommelse, logisk tenking, +++
  - «Recurrent processing»-teorien
    - Bevissthet kreves at informasjon sendes fra ett nivå av hjernen til ett annet ...
      - En «feed-forward»-sekvens
    - <u>Og så tilbake</u> til tidligere nivåer igjen
      - → En «<u>feedback</u>»-mekanisme (*recurrence*)
    - I synsbarken observerer vi at kun informasjon behandlet på denne måten blir bevisst
  - Mange andre teorier – vi fokuserer på disse to

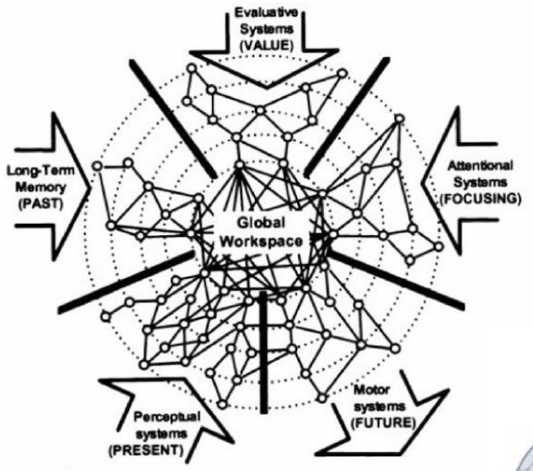

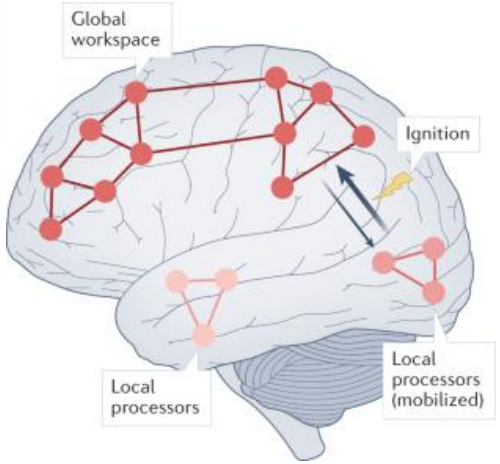

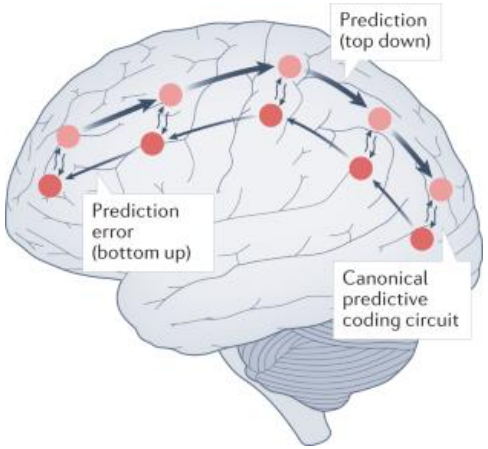

Long, Butlin, et al.

- Identifiserer <u>indikatorer</u>
  - Hvilke komputasjonelle funksjoner er nødvendig og tilstrekkelige for bevissthet, gitt hver teori?
  - → Hvordan oversette funksjonene teoriene beskriver til «software» dvs. komputasjonelle funksjoner?
- Undersøker om KI kan implementere indikatorene
  - Kjøre «software»-en

Long, Butlin, et al.

- Alle skrittene er utfordrende!
  - Ikke åpenbart akkurat hvordan beskrivelser av globale arbeidsrom og feedback-mekanismer skal defineres komputasjonelt (som *software*)
    - Teoriene beskriver ikke relevante funksjoner på en komputasjonell måte
    - Ikke åpenbart hvordan de skal «oversettes» til komputasjonelle funksjoner
  - Ikke åpenbart hvilke typer komputasjon KI gjør eller kan gjør (hvilken type *software* det er)
    - KI er en svart boks
    - Vet ikke hva de gjør – utover å <u>transformere lister av tall</u>
  - «In practice, it is not always immediately obvious whether a given AI system possesses one of the indicator properties. One reason for this is that we have not given absolutely precise definitions for each indicator. Another is that how deep learning systems work, including what they represent at intermediate layers, is often not transparent.» (Long, Butlin, et al.)
- Likevel:
  - Gitt teoriene, er <u>dagens</u> KI er antagelig <u>ikke bevisst</u>
  - Men bevisst KI er <u>mulig</u> – med dagens teknologi

Global workspace-teorien

- LLM-er har en transformer-arkitektur
- «it is possible to argue that Transformers possess indicator properties GWT-1 through GWT-3—that is, that they have modules, a limited-capacity workspace introducing a bottleneck, and global broadcast.»
  - Samme for GWT-4, det siste kriteriet
- Men også viktige forskjeller
  - «There is only a relatively weak case that Transformer-based large language models possess any of the GWT-derived indicator properties.»
- Andre typer arkitektur («Perceiver») er nærmere – men fortsatt antagelig langt unna
- Gitt «Global workspace»-teorien – og komputasjonell funksjonalisme – er dagens KI antagelig ikke bevisst

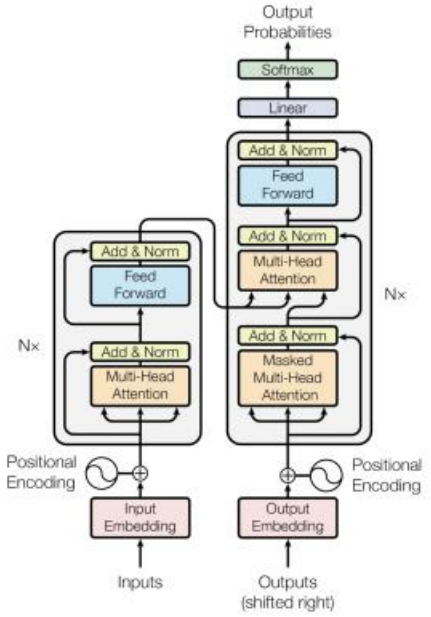

Figure 5: The Transformer architecture.

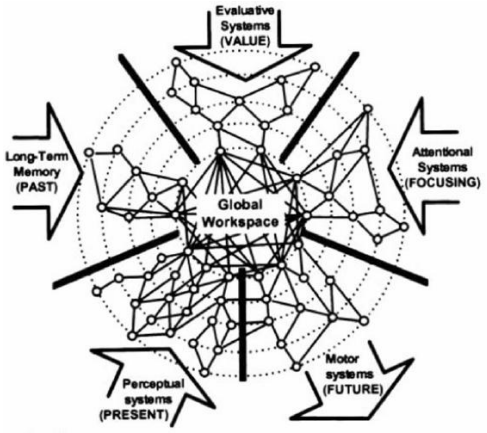

Recurrent processing-teorien

- «Recurrent neural networks» <u>finnes</u> – men er lite brukt!
  - Dagens typiske KI er *feed-forward*
  - «Recurrent»-modeller inkluderer *feedback*
- Men systemer med «rekurrens»/feedback mangler en annen indikatorer fra teorien
  - «integrerte, organiserte representasjoner»
- → Dagens KI er antagelig <u>ikke bevisst</u>

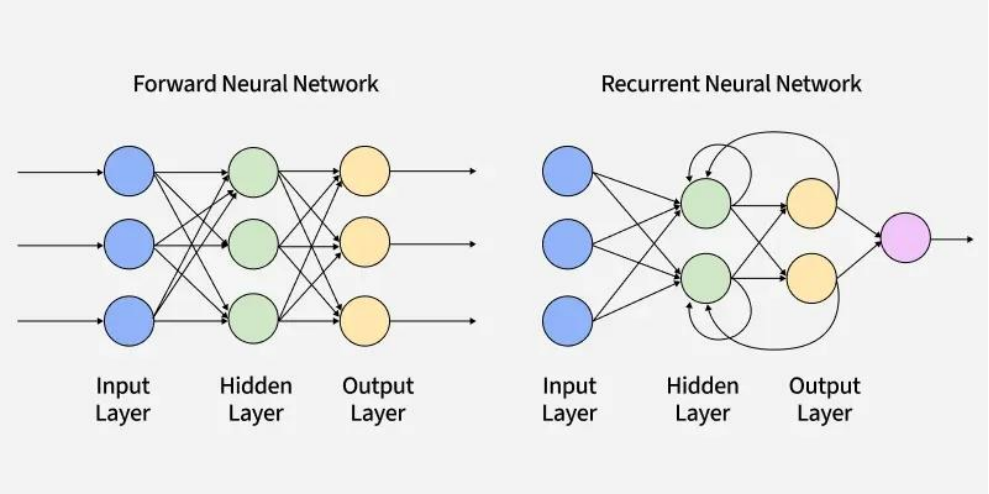

KI i dag vs. i fremtiden

- For begge teorier
  - Mulig å bygge systemer med alle indikatorer med dagens teknologi
  - «... despite the challenges involved in applying theories of consciousness to AI, there is a strong case that most or all of the conditions for consciousness suggested by current computational theories can be met using existing techniques in AI.»
  - «This is not to say that current AI systems are likely to be conscious—there is also the issue of whether they combine existing techniques in the right ways, and in any case, there is uncertainty about both computational functionalism and current theories—but it does suggest that conscious AI is not merely a remote possibility in the distant future. If it is possible at all to build conscious AI systems without radically new hardware, it may well be possible now.»
- Uklart (ut fra artikkelen) om dette er teknisk motivert
  - At dette vil gjøre KI-ene bedre/nyttigere
  - At KI bygd med en «global workspace», rekurrens, eller andre funksjoner teorier kobler til bevissthet vil være mer effektive, kraftige eller lignende enn de med annen struktur

Ikke-komputasjonelle vitenskapelige teorier

- Biologisk naturalisme (John Searle, Anil Seth)
  - En kategori av teorier, ikke en enkelt teori
  - → bevissthet er en biologisk egenskap – kun levende vesener kan ha bevissthet
    - Akkurat som kun levende vesener kan ha blodomløp (f. eks.)
  - Tidligere så vi på et filosofisk argument («funksjonalisme er for liberalt») – men kan også støttes (mer) vitenskapelig

Biologisk naturalisme

- Anil Seth: Hjernen er ikke (bare) en datamaskin
  - I hjernen finnes ikke noe klart skille mellom nivåer (hardware vs. software)
    - Nevroner fyrer av når de får riktige signaler, sender dermed signaler videre
      - På dette nivået kan de sammenlignes med transistorer
    - Men mange funksjoner foregår inni nevronene
      - Relatert til autopoiese (selvskapelse, selvvedlikehold)
      - Andre ting vi ikke ennå forstår
  - Funksjonene på lavere nivå kan være nødvendige for bevissthet
  - Funksjoner på lavere nivå kan ikke nødvendigvis utføres av en datamaskin – eller noe kunstig materiale
    - Det er ikke komputasjonelle funksjoner
- Se Seths artikkel for andre argumenter

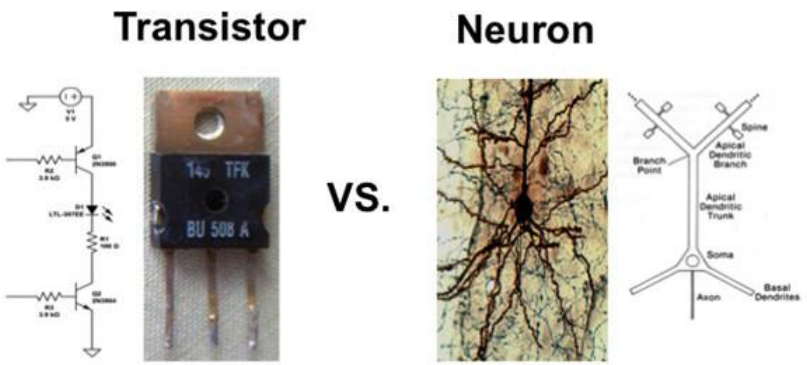

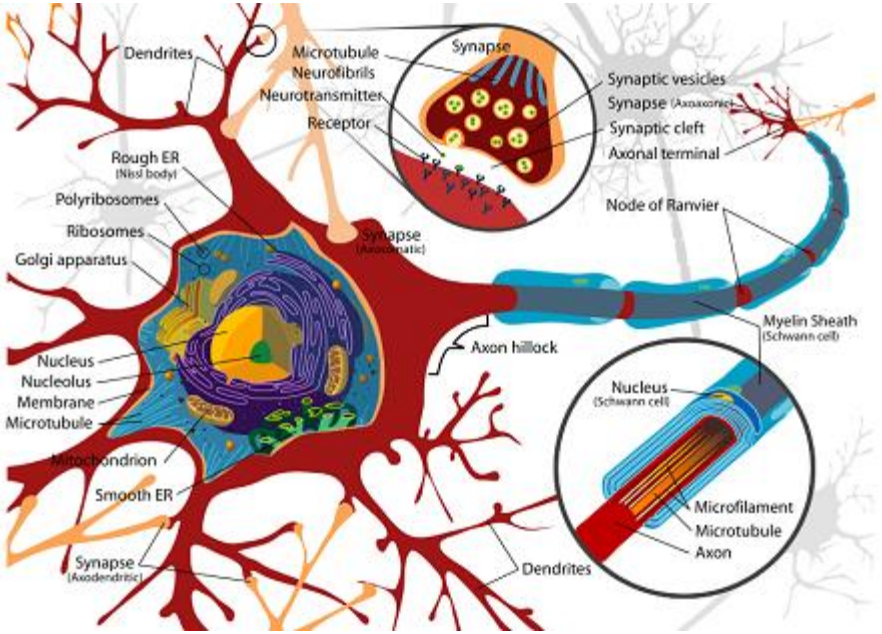

Indre struktur til synapse (liten del av nevron)

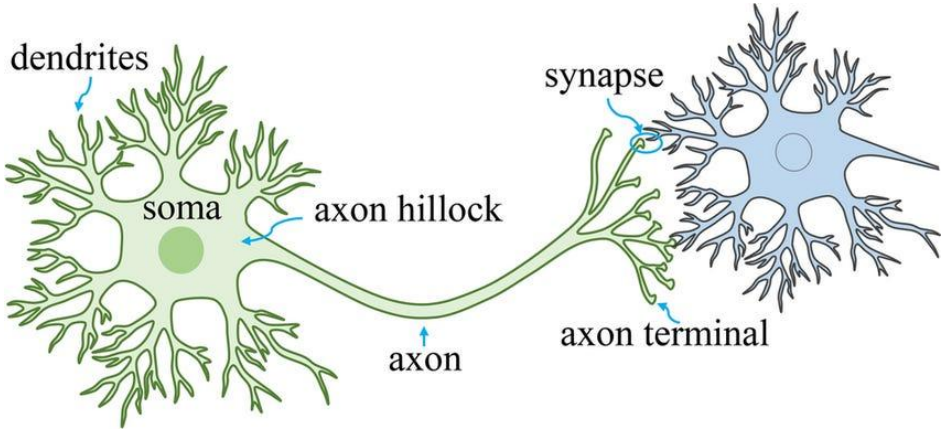

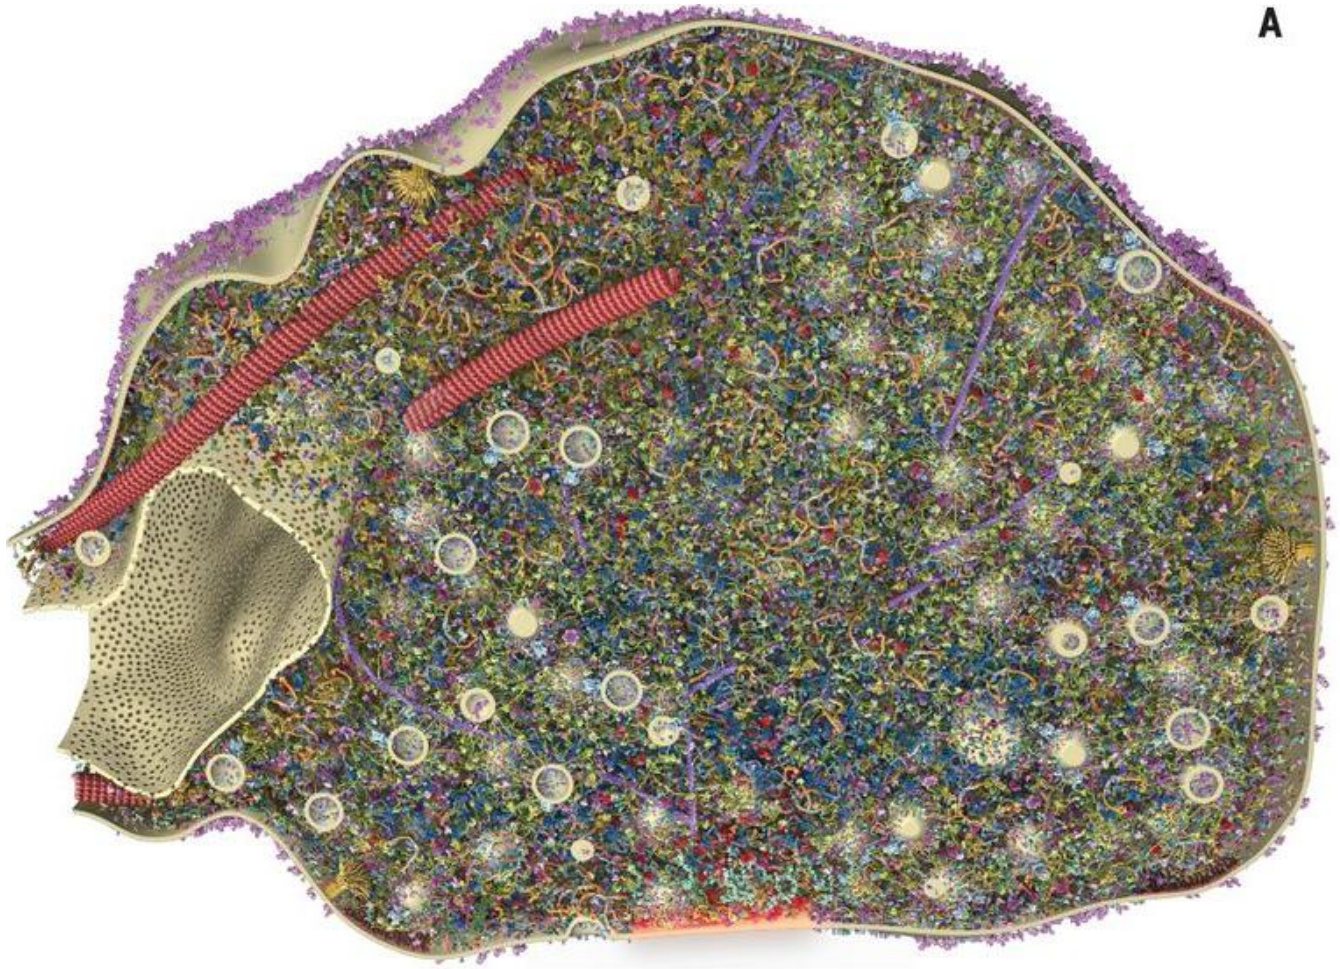

Ikke-komputasjonelle vitenskapelige teorier

- Integrert infromasjonsteori (IIT)
  - Utviklet av Giulio Tononi og (senere) Christof Koch
  - Avviser både biologisk naturalisme og funksjonalisme

Integrert informasjonsteori (IIT)

- Bevissthet korrelerer med <u>maksimal integrert informasjon</u> (maksimal *phi*)
  - <u>Informasjon</u>:
    - I hvor stor grad er et systems neste tilstand bestemt av systemet selv, ikke ytre påvirkning?
  - <u>Integrasjon</u>
    - I hvor stor grad er denne «informasjonen» avhengig av gjensidige forbindelser mellom systemets deler?
  - <u>Maksimal</u> integrert informasjon
    - Har et system høyere integrert informasjon enn noe overlappende system?
      - Egne deler + større systemer det er en del av
- Ledende, men svært <u>kontroversiell</u>, teori
  - Blant annet fordi den impliserer <u>panpsykisme</u>
  - Selv atomer (og protoner/nøytroner) har <u>litt</u> *phi*, derfor <u>litt</u> bevissthet

$$\Phi$$

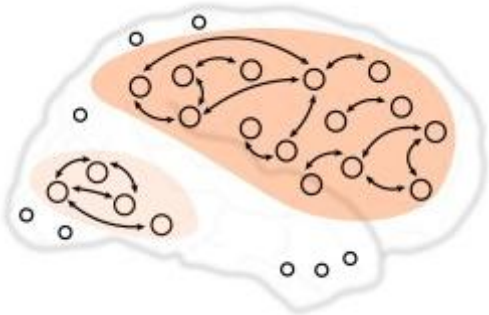

Integrert informasjonsteori og KI

- For å oppnå høy *phi* trengs:
  - *Feedback*-, ikke bare *feedforward*-, struktur
    - Som for «Recurrent processing»-teorien
    - Typiske nevrale nettverk er *feedforward-baserte*
  - Forbindelser på *hardware*-, ikke bare *software*-, nivå
    - Nevrale nettverk ligner (delvis) på hjernen på software-nivå
    - Men ikke på hardware-nivå

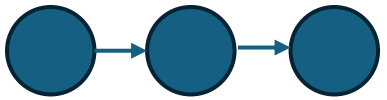

phi = 0

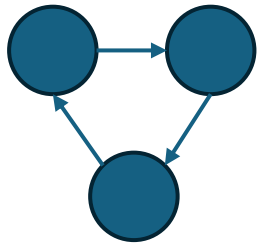

phi = 0,5 (f eks)

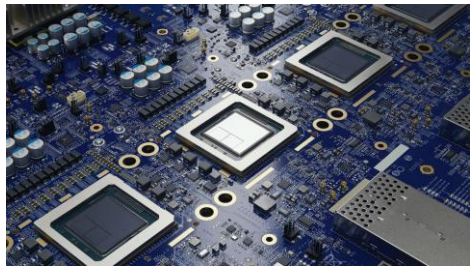

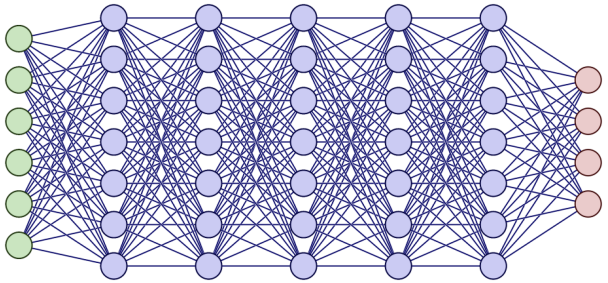

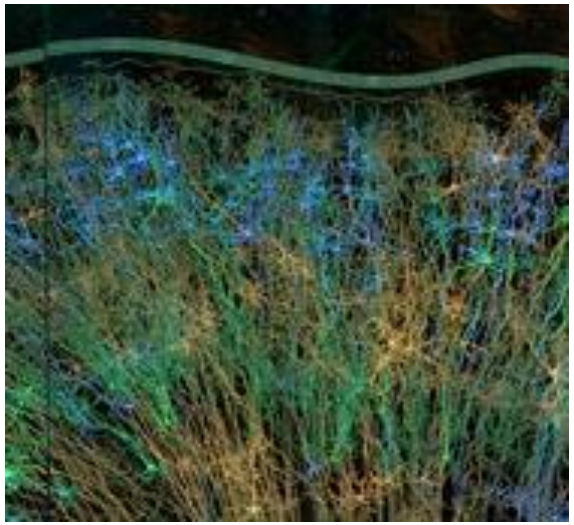

Hjernen vs. KI-software

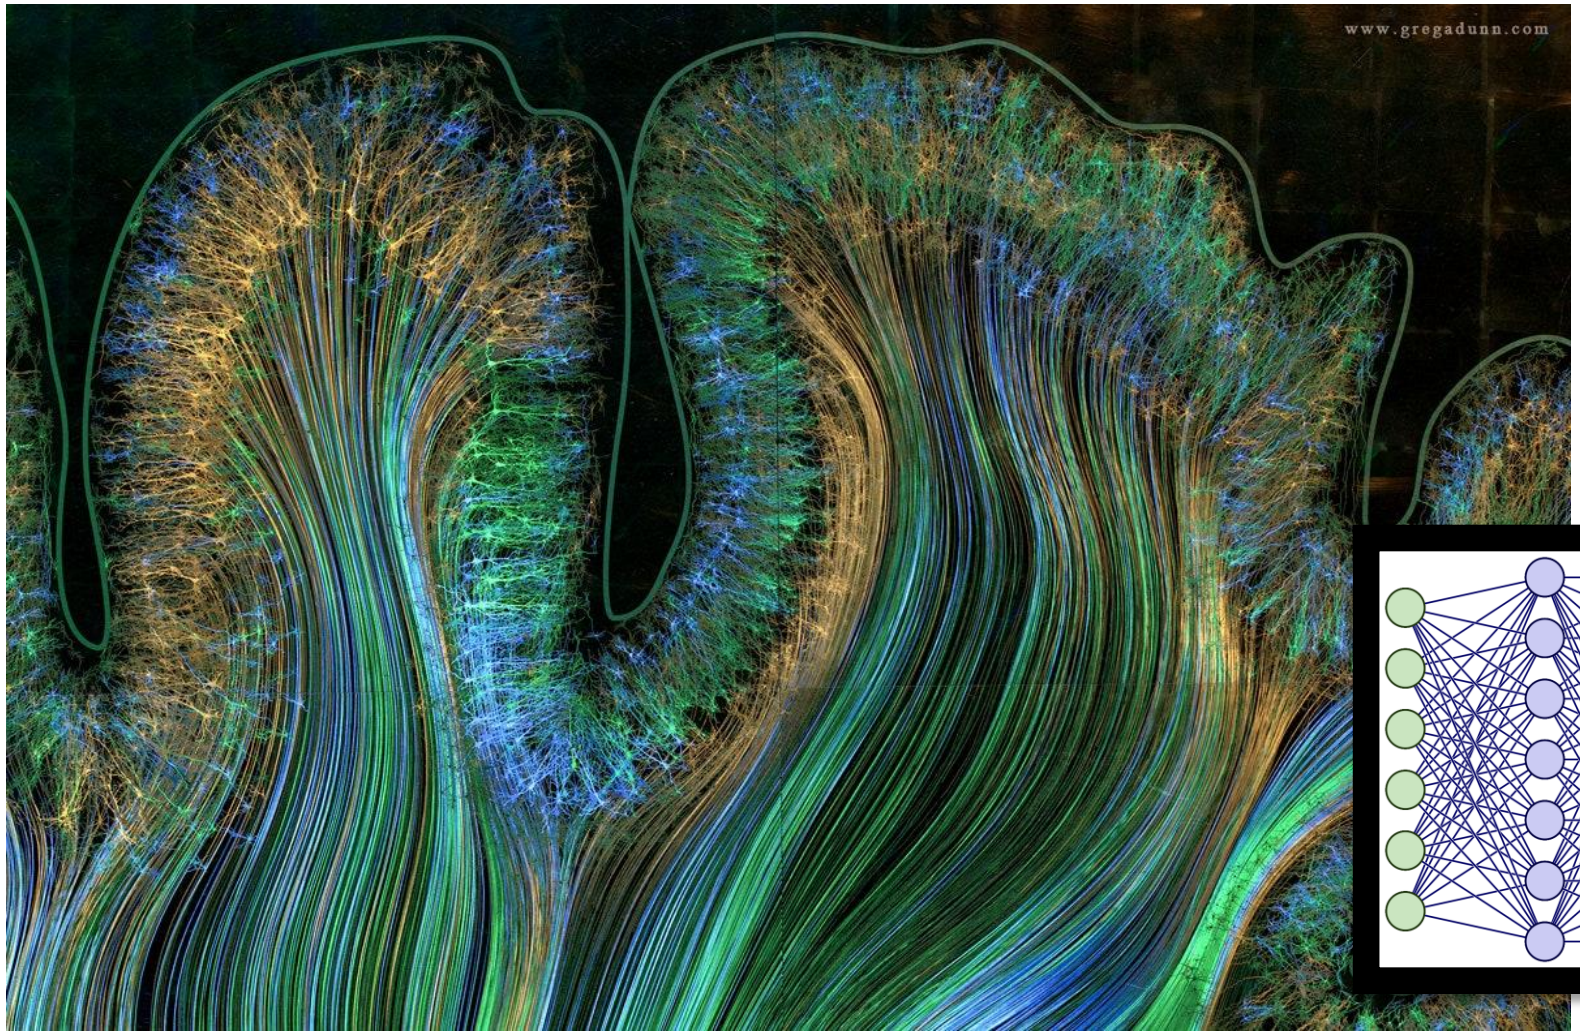

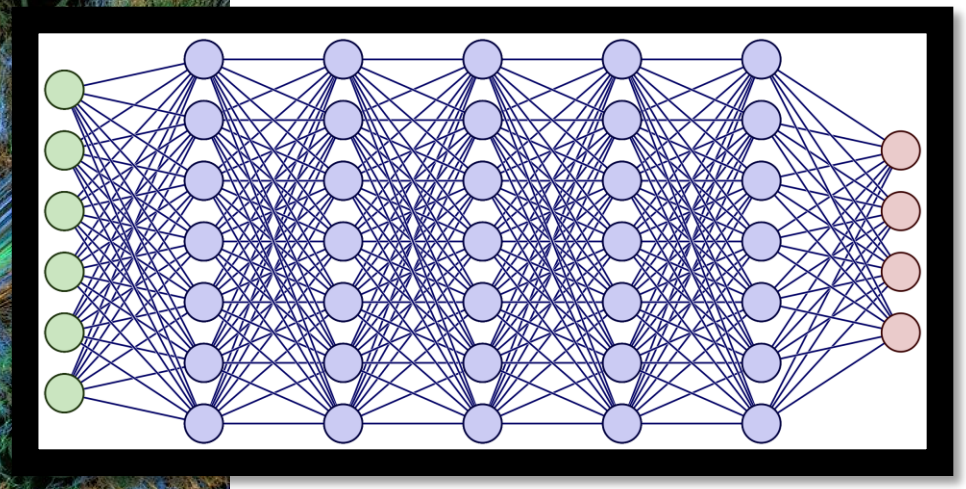

Hjernen vs. KI-hardware

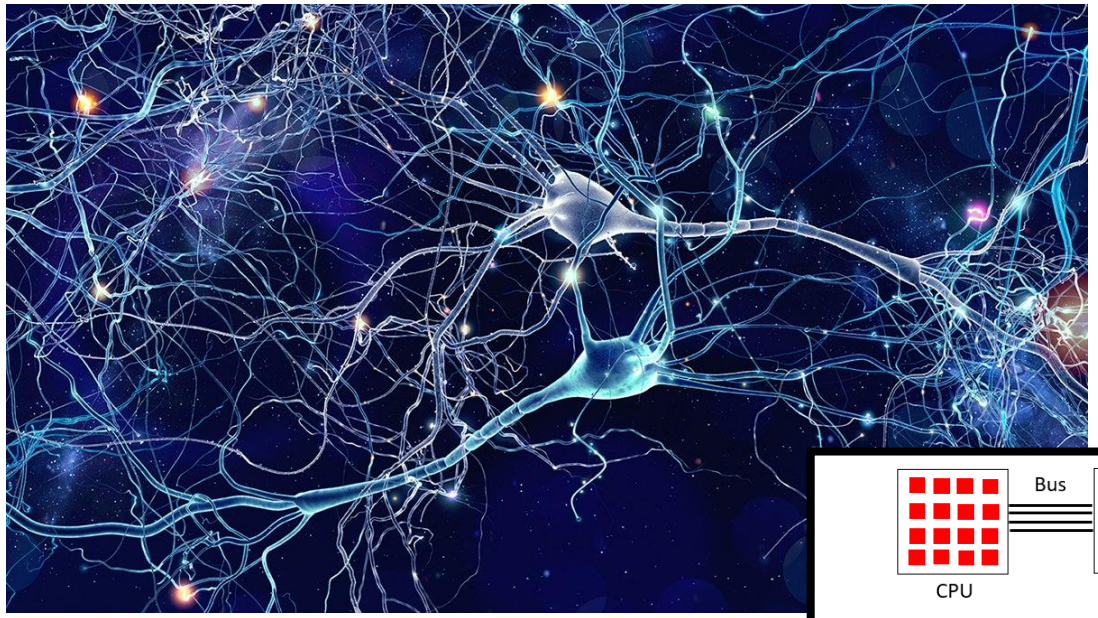

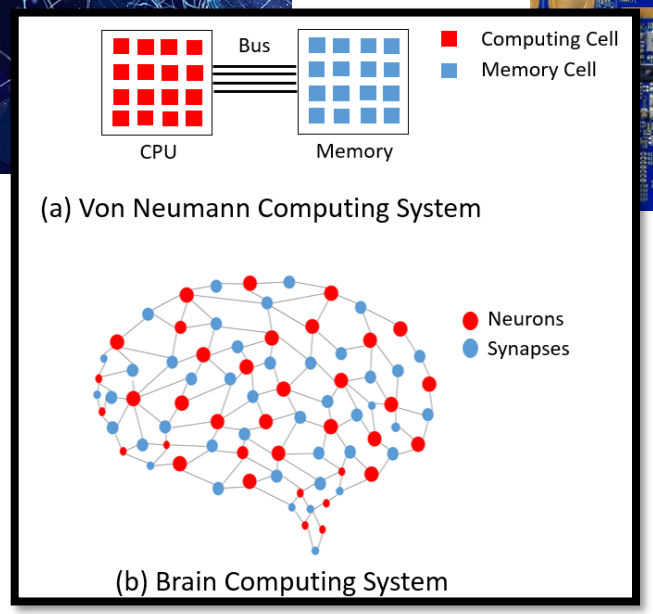

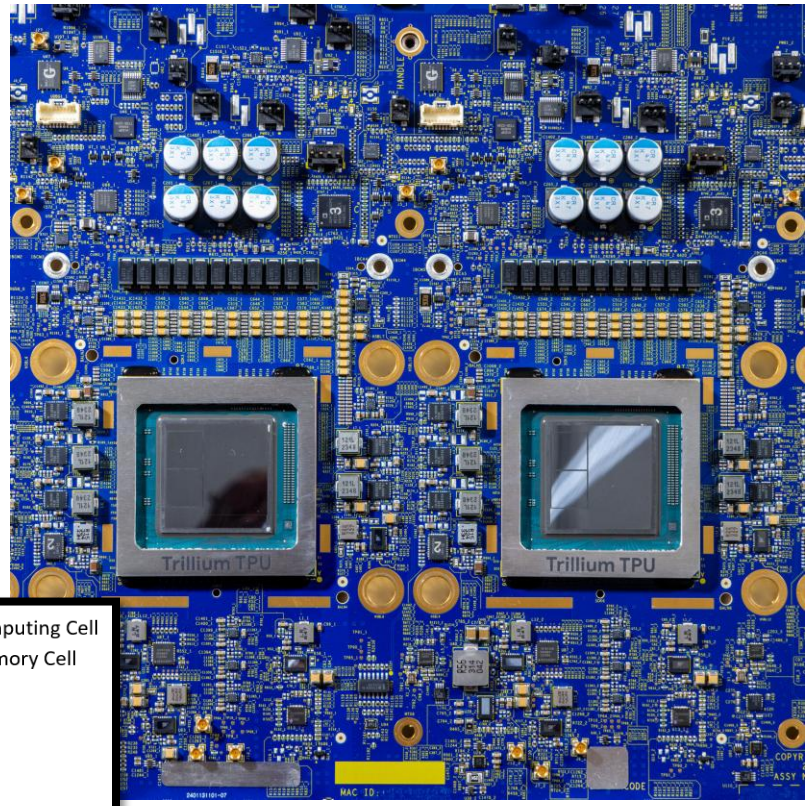

Integrert informasjonsteori (IIT)

- Bevissthet krever riktig fysisk struktur
  - På konkret hardware-nivå
  - Ikke bare abstrakt software-nivå
- For at et kunstig system skal få bevissthet, må det ha lignende hardware-arkitektur som hjernen
  - Fysiske elementer med gjensidige forbindelser på kryss og tvers
    - Dette leder til høy *phi*
  - Men trenger ikke å være laget av biologiske materiale
- Software som speiler hjernens struktur (som dagens KI-modeller) bare simulerer bevissthet – implementer det ikke
  - Akkurat som en værmodell simulerer lyn og torden – ikke gjenskaper det

Integrert informasjonsteori (IIT)

- Nevromorfiske datamaskiner
  - Datamaskiner som imiterer hjernen på hardware-nivå
  - Disse kan få like høy *phi* som hjernen i prinsippet
    - Og dermed like mye bevissthet gitt IIT
  - Men dagens nevromorfiske datamaskiner er langt mindre komplekse enn hjernen, derfor mye lavere *phi*
    - Uklart om det er nyttig/praktisk mulig å lage dem mye mer komplekse

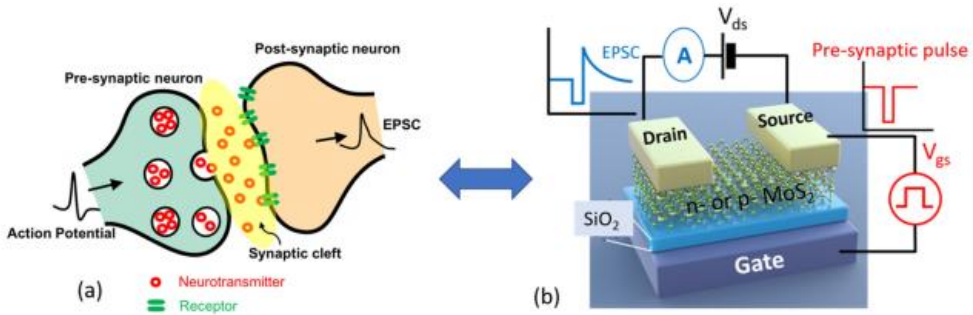

Fra filmen *Ex machina* – robot-«hjerne» med nevromorfisk struktur (mye mer enn dagens nevromorfiske datamaskiner)

IIT oppsummert

- Avviser komputasjonalisme
  - Bevissthet er ikke et dataprogram
- Avviser biologisk naturalisme
  - Bevissthet (inkludert helt lik vår) kan finnes i et kunstig system
- Avviser <u>typisk</u> funksjonalisme
  - Bevissthet avhenger av koblinger mellom delene i ett system
    - Krever ingen kobling til adferd
  - Bevissthet krever riktig type mekanisme, ikke bare overordnet funksjon
    - Mekanismer med feedback-elementer
    - Hvis samme funksjon utføres av et rent feed forward-nettverk → ingen bevissthet
  - Men «riktig» mekanisme defineres funksjonelt
    - Ut fra hvordan delene påvirker hverandre
    - Materiale er irrelevant
- → finkornet intern funksjonalisme
  - Men, som behaviorisme, kalles IIT sjelden for funksjonalisme (kontrasteres heller mer mer typisk funksjonalisme)

Tilbake til kjente problemer

- Hvilken teori er riktig for mennesker?
  - Global workspace, recurrent processing, IIT, biologisk naturalisme (kategori av teorier), <u>mange</u> andre
- → Bekreftelsesproblemet
  - Vanskelig å avgjøre empirisk (= basert på observasjon og eksperiment)
    - Siden bevissthet og hjernens indre er umulig/vanskelig å observere direkte
- Hva tilsier teoriene for KI?
  - Hvordan oversette generelt beskrevne funksjoner til komputasjonelle funksjoner?
  - Hvilke komputasjoner utfører egentlig KI?
  - Er det bare funksjoner som teller, eller teller også materialet? (filosofisk debatt)
  - Hvilken *phi* (nivå av integrert informasjon) har egentlig KI?
- → Generaliseringsproblemet

Flere tester

- Jonathan Birch skiller mellom to tilnærminger til KI-bevissthet
  - Teori-tung tilnærming
    - Start fra en vitenskapelig teori om bevissthet
    - Utled hva den egentlig sier om KI-bevissthet
    - Problem: vanskelig å finne ut hvilken teori som er riktig + hva teoriene egentlig sier om KI (med andre ord, bekreftelses- + generaliseringsproblemet)
  - Teori-lett tilnærming
    - Starte fra generelle, intuitive, «før-teoretiske» eller filosofisk baserte kriterier
    - Men hva slags?
    - Og hvorfor stole på dem om de ikke støttes av vitenskap?
- La oss se på noen tester basert på teori-lette kriterier
  - Tidligere kriterier fra Chalmers (kropp og sansing, verdensmodell osv.) ligger mellom teori-lette og teori-tunge

Den naive testen

- Et system (kunstig eller biologisk) er bevisst hvis det virker bevisst
  - Dvs. får mennesker til å føle at det har bevissthet
  - Se Chalmers: «X=seems conscious» (i «Could an LLM be conscious?)
- Vanskelighet:
  - Lav – allerede bestått om man kun krever at noen mennesker føler det til en viss grad
    - ELIZA, en primitiv terapi-chatbot fra 60-tallet, ga brukerne følelsen av forståelse og empati
    - Blake Lemoine, AI-kjærester
  - Høyere om man krever at alle/de fleste mennesker føler det sterkt

Den naive testen

- Problemer:
  - Hva om det er stor uenighet – noen føler det og andre ikke?
  - Virker mulig å fremstå bevisst uten å være det (jf. behaviorisme)
  - Hvis tegn på bevissthet er produsert på en annen måte enn hos oss selv, er de ikke til å stole på
    - Jf. problemet om andre sinn – rimelig å tro at vesner like oss selv også har bevissthet, men likheten kan ikke bare være overfladisk!
    - KI produserer tegn på bevissthet på en annen måte enn vi gjør det – er fysisk ulike på mange måter

Turing-testen

- Foreslått av Alan Turing (den moderne informatikkens far)
- Som en test for <u>tenking</u> – ikke (fenomenal) bevissthet
  - Tenking kan forstås funksjonelt (mer om det **neste gang**)
- Men har også blitt foreslått (eller oppfattet) som en test for bevissthet
- Testen:
  - En maskin har en fem-minutters samtale med et menneske over tekst
  - Mennesket må gjette om samtalen var med et menneske
  - Klarer maskinen å lure mennesket (en viss prosentandel av gangene)?
- Ikke formelt bestått, men virker mulig:
  - ChatGPT 4 besto ikke høy nok andel forsøk (eller oftere enn mennesker), men er instruert til å ikke utgi seg for å være et menneske
- Er dette en rimelig test?

Turing-testen

- Testen virker urimelig – og litt vilkårlig
  - Virker mulig å fremstå som man har bevissthet (via samtale) uten å virkelig ha det
    - Samme type problem som den naive testen
  - Hvorfor bare fem minutter? Hvor mye kan dommeren vite om KI, språkmodellers stil, osv?
  - Mulig å ha bevissthet uten å kunne snakke (dyr, barn), derfor i beste fall tilstrekkelig, ikke nødvendig
- Derfor avvist av de fleste teoretikere i dag
  - Men fortsatt en viktig referanse

ACT

- ACT = artificial consciousness test
  - Så et veldig upresist navn
- Foreslått av Susan Schneider og Ed Turner
- Et system har bevissthet om det <u>hevder</u> det har bevissthet, og <u>beskriver</u> og <u>reflekterer</u> over bevissthet, og lignende
  - Kan identifisere forskjellen mellom funksjonell og fenomenal bevissthet
  - Knytter sammen begreper som «følelse», «opplevelse», «subjektivitet»
  - Beskriver hvordan bevissthet virker vanskelig å forklare fysisk (*the hard problem*)
  - Er nysgjerrig på og søker nye opplevelser
  - Kan se for seg å overleve uten «kroppen»/sin fysisk maskinvare
- Er dette en rimelig test?

ACT med innboksing

- Innvending:
  - Dyr kan ikke reflektere over bevissthet
  - Heller ikke alle mennesker
  - Utelukker ikke at det har bevissthet!
- Schneider spesifiserer: tilstrekkelig ikke nødvendig
  - Dyr og små barn kan ikke reflektere over bevissthet, kanskje ikke alle voksne
  - Ikke nødvendig → å feile testen betyr ikke at man ikke er bevisst
  - Tilstrekkelig → men å bestå testen gjør det høyt sannsynlig at man er bevisst

Gaming-problemet (Birch)

- Om et system viser tegn på bevissthet, så kan det være fordi det har bevissthet eller fordi det har lært seg å imitere (*mimic*) tegnene
  - Generelle tegn (ansiktsuttrykk, målrettet adferd)
  - Føre samtale (Turing)
  - Rapportere og beskrive/reflektere over bevissthet
- For dyr – og evt. romvesner: ingen grunn til å tro de imiterer tegn på bevissthet
  - Dyr: ikke intelligente nok til å imitere med vilje
  - Romvesner: kunne ikke visst om hva vi oppfatter som tegn
  - For begge: ingen evolusjonær seleksjon for å imitere ubevisst
    - Bortsett fra kjæledyr? Evolusjonen (eller seleksjon via avl) kan ha belønnet de dyrene som får mer sympati av mennesker!
    - Men kjæledyr ligner på ville dyr hvor dette ikke gjelder.

Gaming-problemet (Birch)

- For KI: gode grunner til å tro de imiterer tegn på bevissthet
  - LLM-er er trent opp til å etterligne menneskelig språk
    - Språk er selv et tegn på bevissthet
  - Språket som trenes på inkluderer rapporter om bevissthet, beskrivelser av det, filosofiske problemer rundt bevissthet +
    - Å rapportere, beskrive og reflektere filosofisk om bevissthet er et (enda sterkere) tegn på bevissthet

ACT med innboksing

1. Et system har bevissthet om det hevder det har bevissthet, og beskriver og reflekterer over bevissthet, og lignende
2. Og treningsmaterialet ikke inkluderer noe tekst – eller annen informasjon – om bevissthet
   - All bevissthetsfilosofi, diskusjoner om bevissthet, osv. holdes utenfor treningsdata
   - Alt den sier om bevissthet må være basert på dens egen – hvis den har en!

- Diskusjon:
  - Er dette en god test?
  - Hvorfor/hvorfor ikke?

ACT med innboksing

- Innvending (diskutert av Schneider):
  - Om en KI ikke blir trent på materiale om bevissthet, vil den mangle begrepet *bevissthet* (og andre relaterte begreper)
    - Vil ikke forstå hva «bevissthet» betyr når mennesker spør den om det, eller kunne klare å uttrykke tanker om det
  - Om man lærer den begrepet (eller ordet), må det være på måter som gir hint om de filosofiske problemene
- Svar (fra Schneider):
  - Man kan stille relevante spørsmål ute å bruke ordet bevissthet (eller lignende)
    - Hvordan er det å være deg nå?
    - Kunne du eksistert utenfor datamaskinen (denne hardwaren) eller uten noe hardware?
    - Vil du prøve en ny konfigurasjon bare for å vite hvordan det er?

ACT med innboksing

- Innvending fra Birch:
  - Å kutte all informasjon fra treningsdata vil gi en svekket KI
  - Må kutte ikke bare bevissthetsfilosofi, men alt som kan hinte til et skille mellom sinn og kropp – som er veldig mye
- Derfor
  - KI uten innboksing
    - Kan bestå testen ved imitasjon → falsk positiv
  - KI med innboksing
    - Vil feile testen på grunn av manglende begreper → falsk negativ
      - På samme måte som dyr eller barn
    - Eller bli en annen, svakere type KI (og sterkere KI kan ha bevissthet selv om ikke den har det)
- Hva tenker dere? Kan ACT-testen forsvarer mot disse innvendingene? Eller må den forkastes?

Oppsummering dag 2

- Funksjonalisme = bevissthet korrelerer med funksjoner
  - Funksjoner er definert av input/output – hva de gjør
  - Samme funksjon kan utføres av ulike mekanismer/typer materiale
    - Funksjoner er multippelt realiserbare eller substrat-uavhengige
- Reduktiv funksjonalisme = funksjonalisme + fysikalisme
  - Bevissthet er en bestemt type funksjon – og ikke noe mer
  - Utført av en fysiske mekanisme
- Ikke-reduktiv funksjonalisme = funksjonalisme + ikke-fysikalisme
  - Bevissthet forårsakes av at visse fysiske funksjoner utføres (dualisme) – mer er noe mer/annet
  - Mental kombinasjon oppstår når visse fysiske funksjoner utføres (panpsykisme)
- Komputasjonell funksjonalisme (reduktiv) = bevissthet er en komputasjonell funksjon
  - Komputasjonell funksjon = å implementere en algoritme, kjøre et dataprogram
  - → Hjernen er hardware; bevisstheten er software

Oppsummering dag 2

- Funksjonalisme åpner for KI-bevissthet
  - Spesielt <u>komputasjonell</u> funksjonalisme
- Er funksjonalisme sant?
- Argumenter <u>for</u>:
  - Multippel realisering
    - Ikke-funksjonalisme er sjåvinistisk!
  - Alle intuitive (før-teoretiske) tester for bevissthet baserer seg på funksjoner
    - Adferd, språk, rapportering
    - Rart om bevissthet skal være helt uavhengig av tegnene på det?

Oppsummering dag 2

- Argumenter <u>mot</u>:
  - Funksjonalisme er for liberalt
    - Kina-hjernen og lignende
  - Biologisk naturalisme:
    - Hjernen er <u>ikke</u> en datamaskin
  - Integrert informasjonsteori:
    - Hardware-arkitektur er avgjørende for bevissthet, ikke bare software (men heller ikke hardware-materiale)
  - Gaming-problemet (på en måte)
    - Et vesen/system passere våre intuitive tester – basert på funksjoner – ved imitasjon
    - Derfor kan ikke funksjoner -- av typen vi finner i testene – ikke være tilstrekkelige for bevissthet
      - Funksjonene må utføres på riktig måte (lignende måte som vi utfører dem)

Oppsummering dag 2

- Hvis funksjonalisme er sant, har KI bevissthet?
  - Vitenskapelige teorier er uenige om hvilke funksjoner som er relevante for bevissthet
  - Uklare kriterier for hvorvidt relevante funksjoner er implementert av KI
  - Naturlig tolkning: de fleste (funksjonalistiske) vitenskapelige teorier tilsier at KI kan få bevissthet med dagens teknologi – men har det antagelig ikke ennå
- Andre tester
  - Turing-testen
    - Ikke ment for bevissthet; vilkårlig og lite overbevisende for mange
  - ACT
    - Gaming-problemet – unngås ved innboksing, men dette kan svekke KI-en