Uke/dato	Tid	Tema	Foreleser	Pensum	Ekstra lesning/ressurser
uke 4 23.01	11:15-13:00	Introduksjon: Hva er KI? Filosofiske spørsmål rundt KI. Hva er bevissthet? Hvordan bevissthet spiller en rolle i mange av spørsmålene.	Hedda Hassel Mørch	Russell & Norvig: *Artificial intelligence: a modern approach* (frem til seksjon 27.3 "The ethics of AI". NB! Denne er ment som et generelt overblikk og trenger ikke leses nøye, spesielt ikke seksjon 1.2 og 1.3). Mørch: *Non-physicalist theories of consciousness* (t.o.m. seksjon 1.1.)	NY Times: Links to an external site."Human beings are soon to be eclipsed" Links to an external site. Kurzgesagt: AI – Humanity's final invention? Links to an external site. Teknisk bakgrunn, video: • AI, Deep Learning, and Machine Learning: A Primer Links to an external site. (går gjennom mye av historien i Russell & Norvig; greit overblikk men litt overfladisk på det tekniske) • 3Blue1Brown: Large language models explained briefly Links to an external site. (innføring, sterkt anbefalt!) • 3Blue1Brown: The basics of neural networks, and the math behind how they learn Links to an external site. (liste over videoer som går i mer detalj) Teknisk bakgrunn, artikler: • https://computerhistory.org/blog/how-do-neural-network-systems-work/ Links to an external site. • https://writings.stephenwolfram.com/2023/02/what-is-chatgpt-doing-and-why-does-it-work/ Links to an external site.
	13:45-15:30	Bevissthet I: Problemet om andre sinn + "The hard problem" + funksjonalisme	Hedda Hassel Mørch	Nagel: "Andre sinn" (utdrag fra *Hva er meningen?*) Mørch: *Non-physicalist theories of consciousness* (t.o.m. seksjon 1.4.5; seksjon 1.3.2 trenger ikke leses nøye hvis vanskelig) Chalmers: "Facing up to the problem of consciousness"	TED-talk Links to an external site. med David Chalmers Bayne: "Other minds" (utdrag fra *Philosophy of mind: an introduction*)

				Bayne: "How to be a physicalist" (utdrag fra *Philosophy of mind: an introduction*)	
uke 6 06.02	11:15-13:00	Bevissthet II: Kriterier for maskinbevisshet	Hedda Hassel Mørch	Chalmers: Can a large language model be conscious? Links to an external site. Butlin, Long et. al: "Consciousness in artificial intelligence" (merk: tekniske detaljer i seksjon 2 og 3 er ikke viktige; fokuser på hovedpoengene som er markert i gult) Seth: "The mythology of conscious AI" Links to an external site. (lenke viser til full versjon; forkortet versjon finnes i pensummappen) Mørch: The integrated information theory Links to an external site.	
	13:45-15:30	Bevissthet III: Turing-testen, ACT-testen maskinbevisshet	Hedda Hassel Mørch	Schneider: *Artificial you* (kap. 4) Birch: *The edge of sentience* (kap. 16)	

uke 8 20.02	11:15-13:00	<u>Kognisjon:</u> Kan KI tenke? På samme måte som oss?	Anna-Sara Malmgren	Bayne: "Thought" (utdrag fra *Philosophy of Mind: an Introduction*) Clark: "Meat Machines" (utdrag fra *Mindware: an Introduction to Philosophy of Cognitive Science*)	Searle: "Can Computers Think?" Block: "The Mind as the Software of the Brain" — spesielt avsnitt 2 & 4: 'Intelligence and Intentionality' & 'Searle's Chinese Room Argument'
	13:45-15:30	Etikk I	Andreas Brekke Carlsson	Nyholm: "The Ethics of crashes with self-driving cars. A roadmap" (del 1 og 2) Jenkins, Purves & Strawser: "Autonomous Machines, Moral Judgement, and Acting for the Right Reasons" Carlsson: "Krig uten krigere: Autonome våpen, ansvar og dømmekraft."	Algoritmisk rettferdighet (Stanford encyclopedia of Philosophy): https://plato.stanford.edu/entries/algorithmic-fairness/ Links to an external site.
uke 10 06.03	**12:15-13:00 (merk annen tid + rom -**	Etikk II	Andreas Brekke Carlsson	Long, Butlin et al: "Taking AI welfare seriously" Dung: *Saving Artificial Minds* (kap. 2 og 5)	Claudes "Constitution": Claude's constitution Links to an external site. Goldstein og Lederman: "Claude's right to die?": https://www.lawfaremedia.org/article/claude-s-right-to-die--the-moral-error-in-anthropic-s-end-chat-policy Links to an external site.

	bytte)				
	13:45-16:30 (merk annen tid + rom - bytte)	Etikk III	Andreas Brekke Carlsson	Bostrom: *Superintelligence* (kap. 7) Long, Sebo & Sims: "Is there a tension between AI safety and AI welfare?" Chalmers: "Who do we talk to when we talk to LLMs?"	
uke 12 20.03	11:15-13:00	Samstemthet *(alignment)* og eksistensiell risiko	Hedda Hassel Mørch	Russell & Norvig, seksjon 27.3.7 Bostrom: *Superintelligence* (kap. 7 og 8) Kokatiljo, Alexander, et. al.: "AI 2027" Links to an external site. Jones: "What is AI alignment?" Links to an external site.	Videointroduksjon til "AI 2027" Links to an external site. ChatGPT isn't smart. It's something much weirder. Links to an external site. Diskusjon med Nate Soares, forfatter av If anyone builds it, everyone dies
	13:45-15:30	KI og mening i livet	Hedda Hassel Mørch	Russell & Norvig, seksjon 27.3.5 Bostrom: *Deep utopia* (utdrag) Nozick: "The experience machine" Chalmers: *Reality+* (utdrag)	Marc Andreessen: AI will save the world Links to an external site. Harvey Lederman: ChatGPT and the Meaning of Life Links to an external site.
uke 15 10.04	11:15-13:00	KI og kunst, KI og vennskap	Hedda Hassel Mørch	Hoel: "AI art isn't art" Links to an external site. Nyholm &	Nick Cave om ChatGPT Links to an external site. Tolstoy: What is art? (kap. V) Links to an external site.

				Frank: "It loves me, it loves me not"	
	13:45-15:30	Språk og kommunikasjon	Anna Drożdżowicz	Mallory: "Fictionalism about chatbots" Williams & Bayne: "Chatting with bots: AI, speech acts, and the edge of assertion" NY Times: "How Claude became the tech insiders' chatbot of choice Links to an external site."	
uke 17 24.04	11:15-13:00	KI, samfunnsutvikling og samfunnsverdier	Anstein Gregersen	Langsikt: De ti KI-bud Links to an external site. Aftenposten: Lanserer ti KI-bud for Norge: – Maktubalansen er skremmende Links to an external site. Floridi: *The ethics of artificial intelligence* (kap. 2 og 3) Crawford: *Atlas of AI* (kap. 1 + Conclusion)	
	13:45-15:30	KI, samfunnsutvikling og samfunnsverdier II	Anstein Gregersen	Vallor: *AI mirror* (introduksjon og kap. 2) Summerfield: *These strange new minds* (utdrag)	

uke 19 08.05	11:15-13:00	Transhumanisme	Andreas Brekke Carlsson	Bostrom & Shulman: "Sharing the world with digital minds" Bostrom: "Why I want to be a posthuman when I grow up"	"AI-doom? No problem": https://www.wsj.com/tech/ai/ai-apocalypse-no-problem-6b691772?mod=e2tw Links to an external site. Moen: "Slutten på mennesket slik vi kjenner det": https://www.olemartinmoen.com/transhumanismens-tidsalder/ Links to an external site.
	13:45-15:30	Oppsummering, diskusjon, spørsmål og svar	Hedda, Andreas		